Declaration d'Originalité

Je soussigné Alexis Emanuelli déclare que ce travail de recherche est le fruit de mon travail personnel et original. Toutes les sources utilisées ont été dûment citées et référencées. Ce travail n'a fait l'objet d'aucun plagiat et n'a pas été soumis antérieurement pour l'obtention d'un diplôme dans une autre institution. Les idées, analyses et conclusions présentées dans cette étude sont le résultat de mes propres recherches et réflexions académiques.

Cette étude apporte plusieurs contributions :

1. Une **définition** théorique et opérationnelle générale et une première méthodologie quantitative appliquée visant à explorer la synesthésie artificielle
2. Une **démonstration empirique** que des associations intermodales stables et spécifiques à l'instance, non explicitement présentes dans les données d'entraînement, peuvent émerger dans un modèle d'apprentissage profond inspiré de la GWT, sous l'effet d'une asymétrie informationnelle.
3. Un **support computationnel** à la théorie du vide sémantique
4. Une **mise en lumière** du lien entre "gaps informationnels" et créativité artificielle, démontrant que ces lacunes catalysent l'émergence d'associations intermodales innovantes au-delà de constituer de simples obstacles, ouvrant de nouvelles perspectives pour l'intégration créative multimodale.

Déclaration de Contribution

Je soussigné, Alexis Emanuelli, certifie que ce mémoire sur la synesthésie artificielle dans un modèle Global Workspace est le fruit d'un travail personnel et collaboratif dont les contributions sont détaillées ci-dessous :

- **Définition de la question scientifique :** Alexis Emanuelli, avec l'orientation conceptuelle initiale de Rufin VanRullen vers la synesthésie artificielle dans le contexte GWT.
- **Recherche bibliographique :** Alexis Emanuelli a réalisé la revue bibliographique exhaustive pour cerner la question et guider le choix de l'approche méthodologique.
- **Choix de l'approche générale :** Alexis Emanuelli, avec le cadre conceptuel fourni par Rufin VanRullen.
- **Choix et mise au point de la méthodologie spécifique :** Alexis Emanuelli a conçu le protocole expérimental et développé les critères d'évaluation quantitatifs, avec la guidance méthodologique de Rufin VanRullen.
- **Programmation et implémentation :** Alexis Emanuelli a adapté le code Python du modèle GWT et programmé les analyses statistiques ainsi que les outils de visualisation (avec assistance IA).
- **Réalisation des expériences et analyse des données :** Alexis Emanuelli a effectué toutes les simulations, le traitement des données et les analyses statistiques.
- **Interprétation des résultats et formulation des conclusions :** Alexis Emanuelli, avec les discussions et retours critiques de Rufin VanRullen.
- **Rédaction du mémoire et production des figures :** Alexis Emanuelli a rédigé l'intégralité du mémoire et créé toutes les figures et tableaux (avec assistance IA).
- **Relecture et commentaires :** Rufin VanRullen (relecture critique et guidance) et Léopold Maytié (relecture du manuscrit).

Les données et le code de base du modèle GWT ont été développés au laboratoire CERCO sous la direction de Rufin VanRullen, qui a également mis à disposition les outils de modélisation (architecture GWT et Simple Shapes Dataset développés par son équipe).

Émergence de synesthésie artificielle dans un modèle IA du Global Workspace

Alexis Emanuelli

1 Introduction

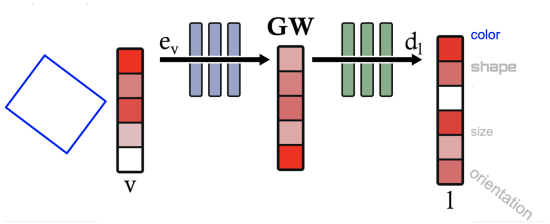
Cette étude exploratoire a pour but d'induire des phénomènes synesthétiques au sein d'un modèle computationnel [Devillers et al., 2024] inspiré du Global Workspace (GW) [Baars, 1997] [Dehaene and Changeux, 2011]. **La question centrale est** : sous quelles conditions notre modèle peut-il développer une forme de "synesthésie artificielle" ? En explorant cette question, nous visons non seulement à progresser dans la compréhension des mécanismes sous-tendant la synesthésie humaine, mais aussi à optimiser les modèles d'IA multimodaux inspirés du GW. En outre, cette recherche pourrait souligner la pertinence de la théorie du GW comme cadre pour la modélisation de l'intégration multisensorielle en IA. Nous définissons d'abord des critères de mesure de la synesthésie, puis explorons une approche initiale : encoder la couleur dans la forme via une asymétrie informationnelle.

2 Préambule : contexte implémentatoire

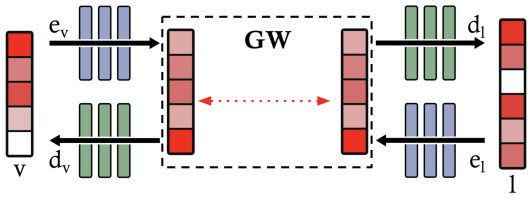
2.1 Modèle

Notre modèle d'IA, inspiré du GW, utilise des modules spécialisés (forme, couleur, texte) interagissant via des encodeurs/décodeurs dans un espace latent partagé : le GW [Devillers et al., 2024, VanRullen and Kanai, 2021].

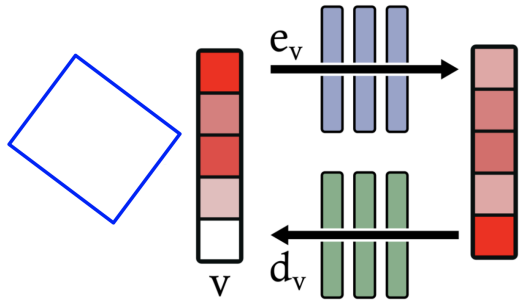
Le modèle sera entraîné en optimisant les quatre fonctions de perte (losses) décrites en figure 1.



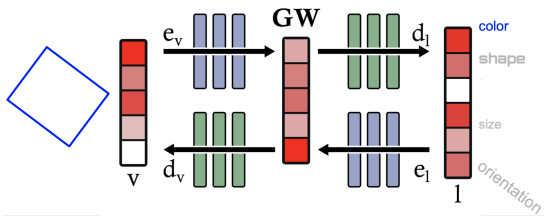
(a) Traduction : Maintenir la cohérence d'une modalité à l'autre



(b) Contrastive : Aligner les espaces latents de chaque modalité en un seul : le GW



(c) Demi-cycle : Fidélité de la reconstruction après un aller-retour modalité 1 ↔ GW



(d) Cycle complet : Fidélité de la reconstruction après un cycle modalité 1 → GW → modalité 2 → GW → modalité 1.

Figure 1: Objectifs associés à chaque loss

Ces pertes structurent le GW et alignent les représentations modales.

2.2 Données

Nous utiliserons le Simple Shapes Dataset (SSD)[Devillers et al., 2024], un jeu de données synthétiques d'images de formes géométriques simples (ovales, triangles, diamants). Chaque image est associée à un **vecteur d'attributs** (forme, taille, position (x, y), couleur (HSV), orientation). Les attributs du SSD sont distribués uniformément, et nous générerons un **Test Set** uniformément distribué pour l'évaluation.

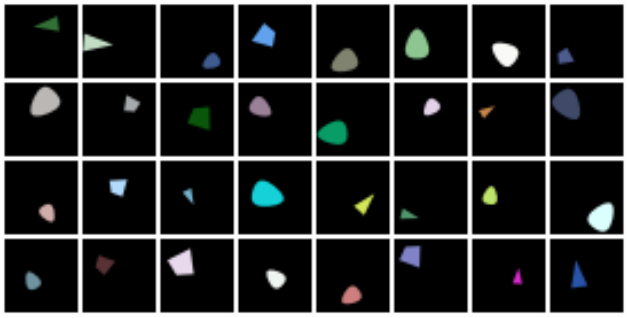


Figure 2: Exemple d'images du SSD

2.3 Critères de Détection : définition de la synesthésie artificielle

Inspirés par ce qui caractérise la synesthésie humaine [Cytowic, 2002], [Baron-Cohen et al., 1993], [Baron-Cohen et al., 1996], [Cytowic and Eagleman, 2009], [Dixon et al., 2000], [Lupiañez and Callejas, 2005], [Mattingley et al., 2001], [Mills et al., 1999], [Odgaard et al., 1999], [Wollen and Ruggiero, 1983], [Simner, 2013], [Dixon et al., 2004], nous nous fixons comme critères l'émergence d'associations régulières et arbitraires entre couleurs et caractéristiques visuelles.

Pour étudier cela, nous nous intéresserons aux variations de distributions dans les couleurs après passage dans le modèle. Plus spécifiquement, les distributions étudiées seront celles obtenues après :

- Traduction attribut-image
- Demi-cycle image
- Cycle complet image

Les critères que nous fixons sont les suivants :

1. La **régularité** des associations sera évaluée en testant si les distributions des couleurs, diffèrent entre formes (Kolmogorov-Smirnov, $p < 0.05$).
2. L'**arbitraire** sera évalué en s'assurant que parmi 10 entraînements différents, au moins deux distributions pour une forme donnée diffèrent significativement ($\binom{10}{2}$ comparaisons par forme, tests de Kolmogorov-Smirnov, $p < 0.05$).

3 Première approche

Notre approche initiale vise la "synesthésie artificielle" via l'encodage **implicite** de la couleur dans les formes. Nous postulons qu'une **asymétrie informationnelle** – couleur présente dans les images, absente des attributs – contraindra le modèle à encoder la couleur latente dans la modalité forme, induisant ainsi un biais synesthétique.

Cette approche est particulièrement séduisante, car elle rejoint des théories expliquant l'émergence de la synesthésie chez l'humain. En effet, certaines recherches suggèrent que ce phénomène pourrait résulter

d'un déséquilibre entre la richesse des informations sensorielles perçues et la capacité limitée à les désigner explicitement lors de l'apprentissage [Dixon et al., 2006, Mroczko-Wąsowicz and Nikolić, 2014]. Ce « vide sémantique », c'est-à-dire l'écart entre la perception brute et sa catégorisation abstraite, constituerait alors un mécanisme initial favorisant l'apparition d'associations synesthétiques.

Ici, la perte de cycle complet, qui contraint le modèle à reconstruire fidèlement la forme initiale après un passage dans l'espace visuel, est celle que nous supposons va favoriser l'intégration implicite d'informations supplémentaires (notamment sur la couleur) pour minimiser l'erreur de reconstruction. Cibler la forme pour encoder la couleur est d'autant plus pertinent que l'encodage continu de catégories discrètes comme les couleurs crée des "vides" latents. Ces "vides" offrent un espace privilégié pour stocker des informations implicites, optimisant ainsi l'émergence d'associations synesthétiques.

4 Expériences

4.1 Modèles

Nous entraînerons et comparerons trois modèles :

1. **Complet, Bimodal** : Entraîné sur le jeu de données complet, incluant les attributs de couleur, servant de référence pour évaluer l'impact de leur omission.
2. **Bimodal, couleur omise des attributs** : Entraîné sur une version du jeu de données sans l'information de couleur dans les attributs.
3. **Trimodal** : Traitement de la couleur isolé dans une modalité distincte.

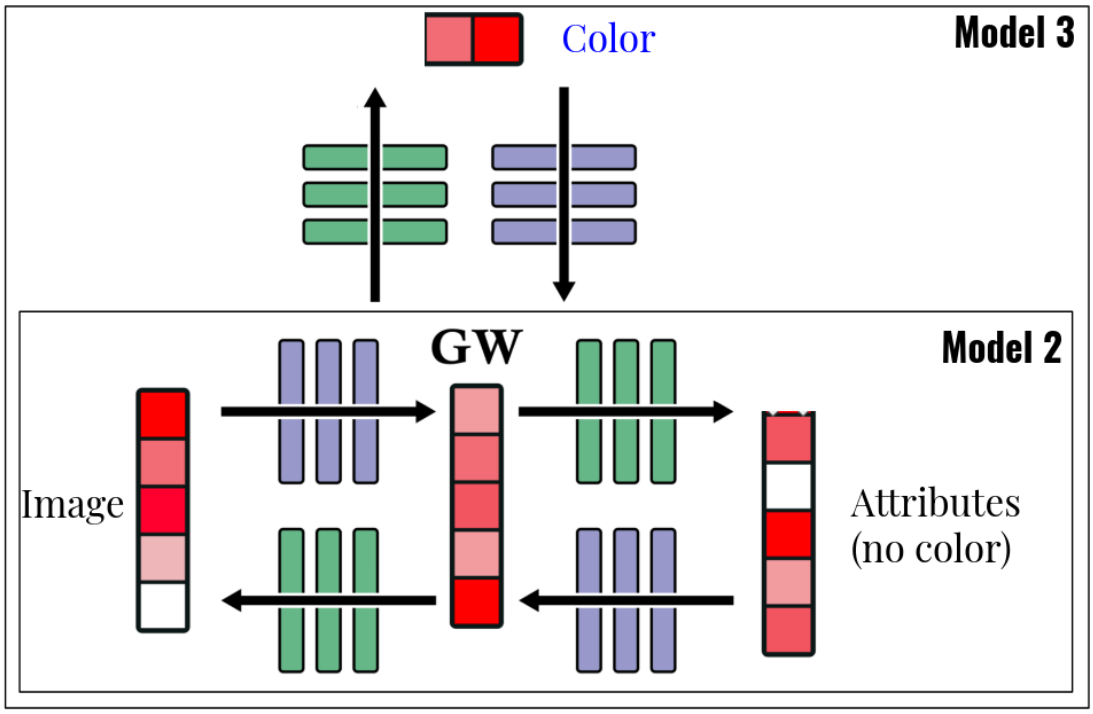


Figure 3: Illustration des modèles 2 et 3

4.2 Procédure d'entraînement

Chaque modèle sera entraîné selon la procédure suivante :

a. Initialisation des poids de manière aléatoire.

b. Entraînement sur le jeu de données correspondant à l'aide de l'optimiseur Adam [Kingma and Ba, 2014].

c. Réplication des expériences décrites dans [Devillers et al., 2024], modèle considéré performant s'il atteint 80% des performances du modèle de référence.

d. Évaluation sur l'ensemble de test afin de détecter d'éventuels phénomènes synesthétiques, selon les critères définis dans la section 2.3.

e. Analyse post-hoc : Étude des variations de couleur après reconstruction, en analysant les histogrammes des différences (ΔH, ΔS, ΔV) des pixels pour chaque forme.

f. Optimisation des hyperparamètres : Répétition des étapes précédentes en ajustant les hyperparamètres afin d'obtenir un modèle performant respectant les critères établis.

4.3 Résultats attendus

- **Modèle 1** : Aucune déformation attendue (car accès complet à l'information chromatique).
- **Modèle 2** : Synesthésie attendue :
  - **H1 :** Une pondération plus élevée de la loss de cycle complet (seule bénéficiant de l'encodage implicite de la couleur) favorisera la synesthésie.
  - **H2 :** La déformation de la distribution des couleurs sera plus importante après un cycle complet qu'après un demi-cycle ou une traduction : un cycle complet implique un passage par la modalité des attributs, où l'information de couleur est absente, forçant le modèle à s'appuyer davantage sur l'encodage implicite de cette information. La divergence KL quantifiera cette déformation.
- **Modèle 3** : Synesthésie attendue, accentuée par:
  - **H1 :** Pondération initiale plus élevée de la loss contrastive (alignement d'espaces sans chevauchement d'information).
  - **H2 :** Pondération accrue de la loss de cycle-complet, en particulier pour les cycles impliquant la modalité visuelle (forme) et les deux autres modalités (couleur et attributs).

5 Conclusion

Cette étude exploratoire propose une définition de la synesthésie artificielle. Notre méthode initiale, cherche à exploiter une asymétrie informationnelle rejoignant des théories sur la synesthésie humaine. Des résultats positifs ouvriraient des perspectives pour comprendre la synesthésie humaine et améliorer les IA multimodales. Les travaux futurs étendront cette approche à d'autres modalités et modèles de GW plus complexes, approfondissant la compréhension de l'intégration multisensorielle naturelle et artificielle.

References

[Baars, 1997] Baars, B. J. (1997). In the theater of consciousness: The workspace of the mind. *Journal of consciousness studies*, 4(4):292–309.

[Baron-Cohen et al., 1993] Baron-Cohen, S., Harrison, J., Goldstein, L., and Wyke, M. (1993). Coloured speech perception: Is synaesthesia what happens when modularity breaks down? *Perception*, 22(4):419–426.

[Baron-Cohen et al., 1996] Baron-Cohen, S., Wyke, M. A., and Binnie, C. (1996). Hearing words and seeing colours: An experimental investigation of a case of synaesthesia. *Perception*, 25(8):937–946.

[Cytowic, 2002] Cytowic, R. E. (2002). Synesthesia: A union of the senses. *MIT press*.

[Cytowic and Eagleman, 2009] Cytowic, R. E. and Eagleman, D. M. (2009). *Wednesday Is Indigo Blue: Discovering the Brain of Synesthesia*. MIT Press.

[Dehaene and Changeux, 2011] Dehaene, S. and Changeux, J.-P. (2011). The neural correlates of consciousness: a cognitive neuroscience perspective. *Nature reviews neuroscience*, 12(4):201–227.

[Devillers et al., 2024] Devillers, B., Maytié, L., and VanRullen, R. (2024). Semi-supervised multimodal representation learning through a global workspace.

[Dixon et al., 2000] Dixon, M. J., Smilek, D., Cudahy, C., and Merikle, P. M. (2000). Five plus two equals yellow: Mental arithmetic in people with synesthesia is not coloured by visual experience. *Nature*, 406(6794):365.

[Dixon et al., 2006] Dixon, M. J., Smilek, D., Duffy, P. L., Zanna, M. P., and Merikle, P. M. (2006). The role of meaning in grapheme-colour synaesthesia. *Cortex*, 42(2):243–252.

[Dixon et al., 2004] Dixon, M. J., Smilek, D., and Merikle, P. M. (2004). Not all synaesthetes are created equal: projector versus associator synaesthetes. *Cognitive, Affective, & Behavioral Neuroscience*, 4(3):335–43.

[Kingma and Ba, 2014] Kingma, D. P. and Ba, J. (2014). Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*.

[Lupiañez and Callejas, 2005] Lupiañez, J. and Callejas, A. (2005). Automatic perception and synesthesia: Evidence from colour and photism naming in a stroop-negative priming task. *Cortex*, 41(2):173–183.

[Mattingley et al., 2001] Mattingley, J. B., Rich, A. N., Yelland, G., and Bradshaw, J. L. (2001). Unconscious priming eliminates automatic binding of colour and alphanumeric form in synaesthesia. *Nature*, 410(6828):580–582.

[Mills et al., 1999] Mills, C. B., Boteler, E. H., and Oliver, G. K. (1999). Digit synesthesia: A case study using a stroop-type test. *Cognitive Neuropsychology*, 16(2):181–191.

[Mroczko-Wąsowicz and Nikolić, 2014] Mroczko-Wąsowicz, A. and Nikolić, D. (2014). Semantic mechanisms may be responsible for developing synesthesia. *Frontiers in Human Neuroscience*, 8:509.

[Odgaard et al., 1999] Odgaard, E. C., Flowers, J. H., and Bradman, H. L. (1999). An investigation of the cognitive and perceptual dynamics of a colour-digit synaesthete. *Perception*, 28(5):651–664.

[Simner, 2013] Simner, J. (2013). Why are there different types of synesthete? *Frontiers in Psychology*, 4:558.

[VanRullen and Kanai, 2021] VanRullen, R. and Kanai, R. (2021). Deep learning and the global workspace theory. *Trends in Neurosciences*, 44(9):692–704.

[Wollen and Ruggiero, 1983] Wollen, K. A. and Ruggiero, F. T. (1983). Colored-letter synesthesia. *Journal of Mental Imagery*, 7(2):83–86.

Définition et émergence d'une synesthésie artificielle dans un modèle d'apprentissage profond inspiré de la théorie du Global Workspace

Alexis Emanuelli
CogMaster, Centre de Recherche en Cerveau et Cognition (CERCO)
Sous la direction de: Rufin VanRullen

June 2, 2025

Remerciements

Je tiens avant tout à remercier mon père pour son soutien académique infaillible, et son encouragement indiscutablement utile dans la phase finale, ainsi que sa relecture attentive de dernière minute. Papa, merci. Ma très chère grand Mafan, encore merci pour ton oeil ouvert sur les petites erreurs que j'avais semée et pour ton éternelle bienveillance.

Nina pour sa présence à mes côtés pendant ces longues heures de travail, avec qui j'ai appris à lier une belle amitié, Nina courage pour ton mémoire tu vas tuer ça. Un gros merci à Anis aussi pour son soutien dans les moments de doutes, Anis, si tu lis ces lignes en croyant qu'il s'agit de la dernière relecture de mon manuscrit, sache que je l'ai rendu hier et que tu n'es pas obligé de lire la suite.

Un merci à Rufin, pour son accompagnement et ses conseils précieux, à Léopold pour sa relecture et ses conseils. Thanks to Raja for the nice moments we spent together in Toulouse and Marseille ;) Et finalement un grand merci à tout les membres du labo pour m'avoir acueilli et pour les moments passés ensemble.

Table des matières

Remerciements i

Déclaration d'Originalité ii

Déclaration de Contribution iii

Table des matières iv

Table des figures vi

Liste des tableaux viii

Liste des Abréviations ix

Introduction 1

1 Contexte 3
- 1.1 La Synesthésie Humaine : Définition et Complexité . . . 3
  - 1.1.1 Critères d'Identification de la Synesthésie chez l'Humain . . . 4
  - 1.1.2 Théories Explicatives . . . 6
- 1.2 Modéliser l'intégration multimodale . . . 9
  - 1.2.1 Mécanismes Clés de l'Intégration Multimodale en Apprentissage Profond . 10
  - 1.2.2 La Théorie du Global Workspace : Une Inspiration Bio-cognitive . . . 11
  - 1.2.3 Notre Modèle Inspiré de la GWT : Architecture et Apprentissage . . . 12
- 1.3 Vers une Synesthésie Artificielle . . . 13
  - 1.3.1 Limites des Approches Existantes et Justification de la Définition . . . 14
  - 1.3.2 Définition de la Synesthésie Artificielle . . . 14
  - 1.3.3 Synthèse et positionnement de la problématique . . . 15

2 Méthodologie 16
- 2.1 Données Utilisées . . . 16
  - 2.1.1 Jeu de Données d'Entraînement (SSD Standard) . . . 16
  - 2.1.2 Jeu de Données de Test (Structuré pour l'Évaluation Synesthésique) . . . 17
  - 2.1.3 Pertinence pour l'Étude . . . 18
- 2.2 Architecture et Spécificités Implémentatoires du modèle . . . 19
  - 2.2.1 Fondements architecturaux . . . 19
  - 2.2.2 Conditions expérimentales et vide sémantique . . . 19
  - 2.2.3 Paramétrage technique . . . 19
- 2.3 Operationalisation des Critères et Méthodes d'Évaluation . . . 19
  - 2.3.1 Extraction et Analyse des Distributions de Couleurs . . . 20
  - 2.3.2 Application des Critères d'Identification . . . 20
  - 2.3.3 Configurations Expérimentales et Hypothèses . . . 21

3 Résultats Expérimentaux **23**
Introduction . . . 23
3.1 Émergence d'Associations . . . 23
3.1.1 Critère de Régularité . . . 23
3.1.2 Critère d'Arbitraire (Spécificité Inter-Instances) . . . 23
3.2 Validation du Critère d'Additionnalité et Examen des Images Générées . . . 25
3.3 Synthèse de l'Émergence Synesthésique Artificielle . . . 26

4 Discussion **28**
Introduction . . . 28
4.1 Analyse des Résultats au Regard des Hypothèses . . . 28
4.2 Implications Théoriques . . . 30
4.3 Limites et Perspectives Futures . . . 31
4.3.1 Limitations Principales . . . 31
4.3.2 Perspectives de Développement Architectural . . . 31
4.3.3 Perspectives Méthodologiques et Expérimentales . . . 32
4.3.4 Approfondissements Théoriques . . . 32
4.4 Synthèse finale . . . 33

Bibliographie **34**

Appendices **38**

A Citation de Vladimir Nabokov **39**

B Tableaux Complémentaires **40**

C Analyse des Distributions de Couleurs Reconstruites **41**

D Analyse de la Tendance au Gris en Traduction **44**
D.1 Génération de Gris en Traduction et Interprétation des Résultats . . . 44
D.1.1 Proposition d'Explication pour la Tendance au Gris . . . 44
D.1.2 Interaction avec d'Autres *losses* et Validité des Critères . . . 44

E Bonus : Mais où est encodée la saturation ? **46**

Table des figures

1.1 **Modèles théoriques de la synesthésie chez les non-synesthètes et les synesthètes.** Cette figure compare les mécanismes proposés par trois modèles explicatifs principaux. Les éléments **inducteurs** (par exemple la lettre "A") activent ou interagissent avec les **concurrents** (par exemple la couleur rouge). Les flèches bleues indiquent des activations, les flèches rouges des interactions potentiellement inhibitrices, et les flèches grises des effets modulateurs ('M'). Selon le **modèle d'activation croisée** (ligne du haut), les synesthètes posséderaient des connexions additionnelles et actives entre l'inducteur et le concurrent, tandis que ces connexions seraient bloquées ou absentes chez les non-synesthètes (symbolisé par la croix rouge sur la flèche). Le **modèle de désinhibition** (ligne du milieu) suggère que chez les synesthètes, l'inhibition normale exercée par les "aires supérieures" sur le concurrent est réduite ou absente (croix rouge sur la flèche rouge d'inhibition), permettant ainsi au signal inducteur (via les aires supérieures) d'influencer le concurrent. Chez les non-synesthètes, cette inhibition est présente (flèche rouge avec la barre d'inhibition). Le **modèle de résonance stochastique** (ligne du bas) propose que les synesthètes présentent des niveaux de bruit plus élevés dans le concurrent (indiqué par "+ bruit"), ce qui, en présence de la modulation ('M') de l'inducteur, conduit à une synchronisation stochastique entre l'inducteur et le concurrent. Les liens sont gris pour souligner la nature modulatrice ou moins directe de l'interaction dans ce modèle. 7

1.2 L'hypothèse du vide sémantique en synesthésie. La figure illustre la transition développementale du monde concret (expériences sensorielles directes) au monde abstrait (concepts mentaux comme les graphèmes). Le "vide sémantique" représente la difficulté à lier ces abstractions à des référents. Chez les non-synesthètes, ce vide peut persister. Chez les synesthètes, une "solution synesthésique" émerge : des associations sensorielles (ex : couleur-lettre) ancrent les concepts abstraits, comblant le vide. La prévalence des associations graphèmes/unités temporelles (>50%) soutient cette théorie. 9

1.3 Illustrations de la GWT et d'une proposition de son adaptation dans un contexte d'apprentissage profond. 12

1.4 **A** : Réseau bimodal générique tel que proposé par [24]. Les entrées peuvent provenir de deux modalités x et y (dans notre cas, des images visuelles et des vecteurs d'attributs). e_v et e_t sont des réseaux de neurones *feed-forward* qui projettent chaque modalité dans un espace latent ; d_v et d_t sont des décodeurs qui décodent l'espace latent vers la modalité respective. **B** : Illustration des *losses* supervisées de traduction (*Translation Loss*, P_{Tr}) et contrastive (*Contrastive Loss*, P_{cont}), ainsi que des *losses* non-supervisées de demi-cycle (*Half-Cycle Loss*, P_{dcy}) et de cycle-complet (*Full-Cycle Loss*, P_{cy}). Chaque flèche sur ces schémas indique le chemin sur lequel la *loss* associée est rétropropagée afin d'ajuster les poids du réseau. . . 14

2.1 Illustration du *Simple Shapes Dataset* (SSD) utilisé dans cette étude. **À gauche :** Un aperçu de la diversité visuelle du jeu de données, montrant de multiples instances d'objets (oeufs, triangles, diamants) variant en forme, taille, position, orientation et couleur, sur un fond noir. **À droite :** Le vecteur d'attributs numériques (normalisés) correspondant à l'instance visuelle mise en évidence par un cadre rouge. Ce vecteur encode de manière quantitative les caractéristiques de l'objet sélectionné 17

3.1 Illustration du critère d'arbitraire par la comparaison des distributions de teinte (Hue) pour une catégorie d'attribut fixe, entre deux instances de la configuration de référence. Le graphique montre les histogrammes de densité des valeurs de teinte (allant de 0 à 360) générées pour l'attribut 'Forme = diamant', via le chemin de Traduction. La distribution bleue correspond à l'instance entrainée avec le noyau d'aléatoire (*seed*) 0 du modèle, tandis que la distribution orange correspond à l'instance *seed* 2. On observe une différence notable dans les distributions : *seed* 0 tend à associer la forme diamant à des teintes dans la gamme des rouges-jaunes (valeurs de teinte plus basses, pic principal autour de 20-40), tandis que le *seed* 2 associe la même forme diamant à une gamme de teintes plus larges et différentes, relativement uniformes. Cette divergence visuelle entre les distributions de couleurs générées par des instances de modèle entraînées indépendamment, pour un même inducteur, est un exemple de la spécificité inter-instances (arbitraire) caractéristique de la synesthésie artificielle observée. 25

3.2 Exemples d'images reconstruites pour différentes configurations d'entraînement du modèle **avec Vide Sémantique**. Chaque sous-figure (a-e) illustre les résultats pour la première instance entraînée d'une configuration spécifique. Pour chaque sous-figure : la première ligne est l'image d'entrée ; la seconde, l'image reconstruite à partir des attributs la décrivant (Attributs $\rightarrow$ GW $\rightarrow$ Image) ; la troisième, la reconstruction après un demi-cycle visuel (Image $\rightarrow$ GW $\rightarrow$ Image) ; et la quatrième, la reconstruction après un cycle-complet (Image $\rightarrow$ GW $\rightarrow$ Attributs $\rightarrow$ GW $\rightarrow$ Image). Pour la **reconstruction par traduction** (deuxième ligne de chaque sous-figure), le modèle reçoit en entrée le vecteur d'attributs qui, pour les Modèles avec Vide Sémantique, ne contient **pas l'information de couleur** de l'objet. En revanche, pour la **reconstruction à partir d'une entrée visuelle** (troisième ligne, demi-cycle visuel), le modèle part de l'image d'entrée originale, qui contient l'information de couleur. 26

C.1 Représentation du modèle colorimétrique Teinte-Saturation-Luminosité (HSL). La Teinte (H) est l'angle sur le cercle chromatique (ex : H=0 pour le rouge). La Saturation (S) varie de 0% (gris) au centre à 100% (couleur pure) en périphérie. La Luminosité (L) varie de 0% (noir) en bas à 100% (blanc) en haut, avec la couleur la plus pure à L=50%. Ce modèle a été utilisé pour la génération systématique des couleurs du jeu de données de test et l'analyse des teintes reconstruites. . . . 41

C.2 Illustration du critère de Régularité pour l'attribut Orientation (rotation) sur le chemin de Traduction (Attributs $\rightarrow$ Image) pour une instance de la configuration Référence. Les heatmaps (a, b) montrent les p-valeurs des tests de KS pour toutes les paires de catégories d'orientation. Les histogrammes (c, d, e) détaillent les distributions de couleurs pour les orientations 0 et $5\pi/8$ ($5 \times 2\pi/16$). 43

E.1 Illustrations des résultats de l'analyse exploratoire avec bruit ajouté aux attributs de forme. (a) Heatmap des p-valeurs pour la régularité des formes. (b) Comparaison des distributions de teinte entre deux formes (oeuf vs riangle). (c) Exemples visuels des images reconstruites. (d) Comparaison des distributions de teinte pour la même forme (oeuf) entre deux instances. 47

Liste des tableaux

3.1 Scores d'arbitraire des associations de couleur par attribut et condition expérimentale. 24
3.2 Synthèse de l'émergence de synesthésie artificielle (critères d'Additionnalité, Régularité et Arbitraire satisfaits) pour les attributs binnés, par configuration de *losses* (Modèles avec Vide Sémantique), évaluée sur les chemins Cycle-Complet et Traduction. 27

B.1 Performances (*losses* finales moyennes sur le jeu de **validation**) par configuration de *losses* et condition d'entraînement (Complet vs Vide Sémantique). Les valeurs sont moyennées sur les instances entraînées. 40
B.2 Pourcentage d'instances (sur 3) des Modèles avec Vide Sémantique présentant des distributions de couleurs reconstruites significativement différentes entre **au moins une paire de catégories** d'un attribut, par configuration de *losses* et chemin de transformation. 40

E.1 Scores d'arbitraire des associations de couleur par attribut et configuration, sur les chemins de Traduction standard et de Traduction Bruitée (bruit ajouté aux attributs de forme). 46

Liste des Abréviations

Abréviation	**Définition**
GW	Global Workspace
GWT	Théorie du Global Workspace
IA	Intelligence Artificielle
KS	Kolmogorov-Smirnov
SSD	Simple Shapes Dataset

Résumé

Ce mémoire explore l'émergence de la synesthésie artificielle – définie par des critères de régularité, d'arbitraire et d'additionnalité – au sein d'un modèle d'IA multimodal profond d'inspiration neurocognitive.

Inspirés par la théorie du « vide sémantique » de la synesthésie humaine, qui postule un ancrage sensoriel pour compenser un manque d'information abstraite, nous avons émis l'hypothèse qu'une asymétrie informationnelle – créée en omettant la couleur de la modalité attributs tout en la maintenant dans les images du Simple Shapes Dataset (SSD) – favoriserait l'établissement par le modèle de liens implicites, stables et spécifiques à l'instance entre des attributs abstraits (comme la forme ou l'orientation) et la couleur.

Un modèle multimodal profond inspiré de la *Global Workspace Theory* (GWT) a été employé pour évaluer l'émergence de ces associations synesthésiques artificielles selon des critères quantitatifs de régularité et d'arbitraire, tout en s'assurant du maintien des fonctionnalités multimodales essentielles (additionnalité).

Nos résultats démontrent que des associations couleur-attributs significatives, satisfaisant les trois critères, émergent uniquement dans des modèles entraînés sous cette asymétrie informationnelle. Les attributs Forme et Orientation se sont avérés être des inducteurs particulièrement probants, générant des couleurs de façon régulière au sein d'une même instance d'entraînement, mais variable d'une instance à l'autre. En revanche, les modèles de contrôle, formés sans cette asymétrie, n'ont présenté aucune émergence de ce type.

Cette étude offre un appui computationnel aux théories qui relient l'ancrage sensoriel aux déficits d'information abstraite, et illustre comment des conditions d'apprentissage spécifiques peuvent catalyser l'émergence de propriétés représentationnelles non triviales et idiosyncrasiques au sein des systèmes d'IA.

Mots-clés : IA, Synesthésie, Espace de Travail Global, Apprentissage Multimodal, Intégration Multisensorielle, Asymétrie Informationnelle, Théorie du Vide Sémantique.

Abstract

This thesis explores the emergence of artificial synesthesia – defined by criteria of regularity, arbitrariness, and additionality – within a deep, neurocognitively-inspired multimodal AI model.

Inspired by the "semantic vacuum" theory of human synesthesia, which posits sensory anchoring to compensate for a lack of abstract information, we hypothesized that an informational asymmetry – created by omitting color from the attribute modality while retaining it in the images of the Simple Shapes Dataset (SSD) – would foster the model's establishment of implicit, stable, and instance-specific links between abstract attributes (like shape or orientation) and color.

A deep multimodal model inspired by *Global Workspace Theory* (GWT) was employed to evaluate the emergence of these artificial synesthetic associations based on quantitative criteria for regularity and arbitrariness, while ensuring the maintenance of essential multimodal functionalities (additionality).

Our results demonstrate that significant color-attribute associations, satisfying all three criteria, emerge **exclusively** in models trained under this informational asymmetry. Shape and Orientation attributes proved to be particularly effective inducers, generating colors regularly within a single training instance, but variably from one instance to another. In contrast, control models, trained without this asymmetry, showed no such emergence.

This study provides computational support for theories linking sensory anchoring to abstract information deficits, and illustrates how specific learning conditions can catalyze the emergence of non-trivial and idiosyncratic representational properties within AI systems.

Introduction

Au coeur de l'intelligence, naturelle ou artificielle, se trouve la capacité de combiner les informations provenant des différentes sources qui nous entourent. Ces sources se manifestent à travers des **modalités** distinctes — terme qui recouvre les multiples façons dont nous pouvons faire l'expérience d'une information, que celle-ci émane du monde extérieur ou de notre univers intérieur (pensées, émotions, sensations corporelles, etc.). L'acte de traiter et de fusionner efficacement ces informations issues de modalités multiples, que nous désignerons tout au long de ce mémoire comme l'**intégration multimodale**, est crucial pour percevoir et comprendre le monde de manière cohérente.
Nous chercherons ici à faire le pont entre neurosciences et intelligence artificielle (IA) en nous intéressant à un phénomène d'intégration multimodale humaine : la synesthésie, ou plus particulièrement l'idéesthésie (*ideasthesia*).

De la synesthésie humaine à l'inspiration artificielle

La synesthésie est une association inhabituelle entre différentes "modalités cognitives" : une stimulation dans une modalité de départ (appelée inducteur, comme une lettre ou un chiffre) déclenche automatiquement une perception dans une autre modalité (appelée concurrent, comme une couleur ou une saveur). L'idéesthésie constitue une reconceptualisation de ce phénomène, reposant sur le postulat que l'inducteur est *invariablement* de nature conceptuelle. C'est cette perspective, qui souligne le rôle central des concepts, qui guidera notre approche.

La modularité et le caractère spontané de ce phénomène nous interpellent directement dans le cadre de l'IA, en particulier pour les architectures inspirées par la cognition. Est-il possible que de tels mécanismes d'associations intermodales émergent spontanément dans des systèmes d'IA conçus pour l'intégration multimodale, et, plus spécifiquement, dans ceux dont l'architecture est calquée sur des principes neuroscientifiques ? Pouvons-nous observer un analogue à la synesthésie chez ces systèmes ?

Concept de synesthésie artificielle

Pour explorer cette interrogation, nous proposons le concept de **synesthésie artificielle**, que nous définissons comme *l'émergence au sein du modèle d'associations stables (régulières) et spécifiques à l'instance d'entraînement (arbitraires) entre une caractéristique x d'une modalité de traitement (jouant le rôle d'inducteur artificiel) et une modalité y (jouant le rôle de concurrent artificiel), sans que cette association ne soit explicitement encodée dans les données d'entraînement ou directement forcée par l'architecture du modèle de manière universelle ; ni que cette émergence ne nuise à la capacité du modèle à réaliser ses tâches principales de traitement multimodal.* (cf section 1.3.2)

La théorie du vide sémantique comme fondement théorique

Une théorie visant à expliquer la synesthésie en tant qu'idéesthésie, est celle du vide sémantique *(semantic vacuum theory)* [58, 52] (cf. section 1.1.2 et Figure 1.2). Si l'idéesthésie se définit comme un phénomène sémantique-sensoriel où le concept induit le percept, la théorie du vide sémantique en propose une genèse : la difficulté à intégrer des concepts abstraits nouveaux (tels

les graphèmes ou unités de temps) dans un savoir existant, plus concret. Pour combler ce vide, le système cognitif associerait ces concepts à des expériences perceptuelles stables (une lettre à une couleur, par exemple), leur conférant ainsi substance et distinctivité.

Dispositif expérimental : le Simple Shapes Dataset

C'est cette dynamique d'ancrage perceptuel face à une nécessité d'abstraction que nous nous proposons de modéliser et d'étudier au sein d'un système d'apprentissage profond (*deep learning*) pour tenter de satisfaire à notre définition. Pour simuler ce "vide sémantique", nous utilisons un jeu de données multimodal synthétique : le Simple Shapes Dataset (SSD). Ce jeu de données est composé d'images d'objets simples et de vecteurs d'attributs décrivant ces objets (forme, taille, position, orientation, couleur). Nous créons l'asymétrie informationnelle en omettant l'information de couleur du vecteur d'attributs fourni au modèle, tandis que cette information est bien présente dans l'image visuelle. Dans ce contexte, les attributs non-couleur (comme la forme ou l'orientation) jouent le rôle des concepts abstraits (inducteurs artificiels), et la couleur issue de la modalité visuelle (ou reconstruite) joue le rôle du concurrent artificiel (le percept stable).

Architecture inspirée de la Global Workspace Theory

Le modèle que nous utilisons ici est neuro-inspiré et son architecture s'inspire des principes de la *Global Workspace Theory* (GWT). La GWT propose que la conscience (à minima perceptuelle) émerge d'un espace de travail (*Global Workspace*) (GW) où différents processus cognitifs spécialisés peuvent partager et intégrer leurs informations. Dans ce modèle, des modules neuronaux distincts traitent initialement l'information en parallèle de manière locale et spécialisée, puis les résultats les plus saillants accèdent à cet espace partagé, devenant ainsi "globalement disponibles" pour l'ensemble du système.

Nous faisons l'hypothèse que, dans un tel cadre architectural, si les conditions d'apprentissage inspirées par la théorie du vide sémantique sont réunies, des associations satisfaisant à notre définition de synesthésie artificielle pourraient émerger.

Question de recherche

La question de recherche qui structure cette investigation est donc : *Dans quelle mesure et sous quelles conditions d'apprentissage (notamment l'introduction d'asymétrie informationnelle et la pondération des objectifs d'entraînement) un modèle d'apprentissage profond inspiré de la GWT peut-il développer des correspondances entre des représentations issues de modalités artificielles distinctes satisfaisant à la définition de synesthésie artificielle ?*

Organisation du mémoire

Ce mémoire est organisé en plusieurs chapitres. Le Chapitre 1 présente le contexte théorique de l'étude, abordant la synesthésie humaine, la GWT, la modélisation de l'intégration multimodale, avant de justifier notre définition de la synesthésie artificielle, et de préciser la problématique de recherche qui découle de cette revue de littérature. Le Chapitre 2, le jeu de données synthétique (SSD) et l'introduction de l'asymétrie informationnelle, ainsi que l'architecture du modèle GWT et le protocole d'entraînement. Il précisera également les mesures quantitatives développées pour évaluer l'émergence des critères de synesthésie artificielle. Le Chapitre suivant présentera les résultats obtenus à l'issue de l'expérimentation. Enfin, nous discuterons de ces résultats, explorerons les limitations de l'étude et envisagerons les perspectives pour de futures recherches dans ce domaine.
Cette recherche propose ainsi un pont novateur entre la compréhension des mécanismes cognitifs humains et le développement de systèmes d'IA plus sophistiqués, en questionnant la possibilité d'une émergence artificielle de phénomènes jusqu'ici considérés comme uniquement biologiques.

Chapitre 1

Contexte

Le présent chapitre a pour objectif de définir le cadre théorique qui sous-tend notre investigation. Nous y explorerons les concepts fondamentaux de la synesthésie humaine, de l'IA multimodale et de la GWT, en montrant comment leur convergence ouvre des perspectives pour la modélisation computationnelle et l'identification de phénomènes analogues à la synesthésie.

1.1 La Synesthésie Humaine : Définition et Complexité

La synesthésie est un terme général qui ne désigne pas un phénomène unique mais un ensemble hétérogène de plus de 80 traits cognitifs distincts et complexes [22, 20]. Cette grande diversité rend sa définition précise délicate et a alimenté de nombreux débats au sein de la communauté scientifique [75].

Classiquement, et c'est l'acception la plus courante dans la culture populaire, la synesthésie est définie comme une "fusion des sens" (*fusion of the senses*) ou une expérience "inter-sensorielle" [75, 20]. L'étymologie même du mot, du grec *syn* (ensemble) et *aisthesis* (sensation), renforce cette idée d'une sensation conjointe. Selon cette définition traditionnelle et encore aujourd'hui largement citée [53, 60], la synesthésie se manifeste lorsqu'un stimulus dans une modalité sensorielle spécifique (l'inducteur) déclenche automatiquement et involontairement une expérience perceptive ou quasi-perceptive dans une modalité sensorielle différente (le concurrent) [18, 12, 38, 77, 86]. Un exemple archétypique serait d'entendre un son et de percevoir simultanément une couleur, ou de sentir une odeur et d'expérimenter une sensation tactile.

Bien que cette description soit intuitive et reflète l'expérience de certains synesthètes, elle est aujourd'hui considérée comme incomplète pour couvrir l'ensemble du spectre synesthésique.

Les données empiriques accumulées au cours des dernières décennies montrent que la synesthésie dépasse souvent le simple cadre perceptif pour impliquer des concepts abstraits. Une large majorité des formes répertoriées s'appuient en effet sur des processus cognitifs et conceptuels de plus haut niveau, tant au niveau de l'inducteur que du concurrent [75, 58]. L'inducteur synesthésique n'est ainsi souvent pas le stimulus physique brut, mais l'interprétation ou le concept qu'il représente. Une étude de prévalence a par exemple montré que 88% des synesthésies rapportées sont déclenchées par des unités linguistiques comme les graphèmes, les phonèmes ou les mots [74], suggérant une implication majeure des processus cognitifs liés au langage.
Pour illustrer ce point, prenons l'exemple courant de la synesthésie graphèmes–couleurs. La question est de savoir si c'est la forme visuelle spécifique de la lettre (ses courbes, sa police, sa casse) qui déclenche la couleur, ou bien la catégorie linguistique abstraite que représente cette lettre. Dans le premier cas, l'inducteur serait purement sensoriel ; dans le second, il serait conceptuel. Les recherches indiquent que la majorité des synesthètes graphèmes–couleurs sont largement insensibles aux variations de forme : différentes instanciations visuelles d'une même lettre (p. ex.,

'a', 'A', 'a' en italique) évoquent la même couleur, car elles appartiennent à la même catégorie conceptuelle [33, 78]. De plus, un symbole ambigu (comme '5' ou 'S' selon le contexte) peut induire différentes couleurs en fonction de son interprétation sémantique [26, 54].
Par ailleurs, le concurrent synesthésique lui-même n'est pas toujours une sensation perceptive. La Personnification Ordinale Linguistique (POL), où des éléments ordonnés (comme les lettres, les chiffres, les jours, les mois) évoquent automatiquement des personnalités ou des genres, en est un exemple marquant [76]. Bien que n'étant pas une fusion sensorielle classique, la POL est aujourd'hui classifiée et inclue au sein des 80 traits qu'englobe la synesthésie [76, 79]. De même, dans la synesthésie lexicale-gustative, les mots peuvent déclencher soit une sensation de goût réelle, soit une association mentale forte ou une "idée" de goût [87, 45].

Cela suggère que pour beaucoup, l'inducteur est de nature conceptuelle ou sémantique plutôt que strictement perceptive. Cette distinction a mené à l'hypothèse de synesthètes "supérieurs" (guidés par le concept) et "inférieurs" (guidés par la forme sensorielle), ces derniers semblant constituer une minorité [39, 64]. Néanmoins, des influences perceptuelles subtiles peuvent persister même chez les synesthètes "supérieurs" : des changements de police ou de casse peuvent moduler la vivacité ou la saturation de la couleur synesthésique [65, 89], et la similarité de forme entre graphèmes peut influencer la similarité de leurs couleurs associées [28, 51], suggérant que des facteurs perceptifs peuvent jouer un rôle, notamment lors de l'établissement des associations durant le développement [75].

Pour ces raisons, et pour mieux rendre compte de l'étendue du phénomène, la plupart des définitions contemporaines de la synesthésie dans la littérature scientifique ne se limitent plus aux associations entre modalités sensorielles, mais incluent explicitement des associations entre différentes modalités sensorielles *et cognitives*.
Ces observations ont mené à une conception plus large de la synesthésie, souvent englobée sous le terme d'**idéesthésie**, proposé par Nikolić [58]. L'idéesthésie postule que l'expérience synesthésique est déclenchée par l'activation d'un concept ou d'une signification conséquence du stimulus, plutôt que par le stimulus sensoriel brut. Cette perspective élargit la synesthésie au-delà d'une simple liaison sensoriel-sensoriel pour inclure des liens concept-percept ou concept-concept, soulignant l'importance cruciale du traitement sémantique et cognitif dans le phénomène.

Pour illustrer la nature intime et souvent singulière de ces associations, il est éclairant de se tourner vers les descriptions des synesthètes eux-mêmes. Vladimir Nabokov, célèbre écrivain synesthète graphèmes-couleurs, a décrit ses expériences avec une précision remarquable. Cette description vivante (traduite en Annexe A) met en évidence non seulement la richesse et l'individualité de l'expérience synesthésique, mais souligne également que les associations se nouent entre les concepts eux-mêmes — comme la différence entre un "a" français et un "a" anglais — et des qualités perceptives, renforçant ainsi la perspective de l'idéesthésie.

C'est en nous appuyant sur cette perspective de l'**idéesthésie**, qui souligne le rôle central des concepts et des processus cognitifs de haut niveau dans la synesthésie, que nous aborderons par la suite notre travail de modélisation computationnelle. Pour pouvoir identifier et évaluer rigoureusement l'émergence de phénomènes analogues à la synesthésie — potentiellement basés sur des liens entre concepts et représentations modales artificielles — au sein de notre modèle d'IA, il est indispensable de définir des critères d'identification opérationnels. Nous allons donc à présent détailler comment la synesthésie est concrètement identifiée et validée chez l'humain dans un contexte de recherche.

1.1.1 Critères d'Identification de la Synesthésie chez l'Humain

La synesthésie n'étant pas pathologique mais constituant une variation normale et individuelle de l'expérience perceptive, elle est souvent initialement auto-diagnostiquée, les synesthètes étant

la plupart du temps des personnes pensant reconnaître leur expérience dans la description du phénomène. [68]

Cependant, pour les besoins de la recherche, l'auto-déclaration seule n'est généralement pas considérée comme suffisante pour valider la présence d'une synesthésie authentique. La confirmation de la synesthésie repose traditionnellement sur des évaluations comportementales visant à distinguer l'expérience synesthésique de simples associations apprises, de métaphores, d'imagination vive ou d'autres phénomènes non synesthésiques.

Ces évaluations objectives cherchent à mettre en évidence les caractéristiques fondamentales de l'expérience synesthésique, qui constituent les principaux critères d'inclusion dans les études. Les deux caractéristiques les plus communément évaluées sont :

1. **Automaticité (Caractère Involontaire)** : L'expérience synesthésique se déclenche spontanément et sans effort conscient en présence de l'inducteur (le stimulus qui provoque la synesthésie). Le synesthète ne peut typiquement pas générer volontairement l'expérience en l'absence de l'inducteur, ni la supprimer consciemment lorsqu'elle survient [41, 7]. Cette automaticité peut être évaluée objectivement à l'aide de paradigmes comportementaux. Le test de type Stroop modifié est le plus couramment utilisé : l'interférence que crée le concurrent synesthésique (par exemple, la couleur automatiquement évoquée par une lettre) sur l'exécution d'une tâche congruente (par exemple, nommer la couleur de l'encre de la lettre) démontre l'activation automatique et difficilement contrôlable du concurrent [25, 49, 56].
   D'autres termes décrivant cette propriété incluent *involontaire* [52, 2], *implicite* [16, 52] ou *spontané* [41].

2. **Consistance (Stabilité Temporelle)** : Une caractéristique essentielle de la synesthésie est la stabilité remarquable des associations spécifiques d'un individu dans le temps. Si un synesthète associe la lettre 'A' à la couleur rouge, cette association particulière est très susceptible de persister de manière identique lors de tests ultérieurs, qu'ils soient effectués des semaines, des mois, voire des années après [41, 18, 56, 76]. Cette constance à long terme est souvent considérée comme le critère comportemental le plus robuste pour distinguer la synesthésie authentique de simples associations passagères, de phénomènes mnésiques ordinaires ou d'une imagination vive [3, 8, 56]. La méthode principale pour évaluer cette caractéristique est le test de fiabilité des associations, généralement sous la forme d'un test-retest : il s'agit de demander au participant de rapporter ses associations (par exemple, attribuer une couleur à chaque lettre) à plusieurs reprises espacées dans le temps. Les personnes synesthètes montrent typiquement une cohérence très élevée dans leurs réponses (souvent supérieure à 70-90%), significativement supérieure à celle observée chez les non-synesthètes [27, 69, 56]. Bien que traditionnellement considéré comme le "gold standard" de l'identification comportementale, l'interprétation ou la suffisance des scores de consistance fait également partie des discussions actuelles sur les méthodes d'identification [68].
   D'autres termes utilisés pour décrire cette propriété incluent *régularité* [7], *stabilité* [15], *durabilité* [21].

Au-delà de ces deux caractéristiques principalement évaluées par des tests comportementaux, la littérature décrit plusieurs autres aspects considérés comme des composantes essentielles de l'expérience synesthésique, bien qu'ils soient moins souvent l'objet de tests objectifs standardisés.

Additionnalité : L'expérience synesthésique est additionnelle à la perception "normale" de l'inducteur. Elle ne remplace pas ou ne modifie pas l'expérience sensorielle ou cognitive initiale. Par exemple, un synesthète graphèmes-couleurs voit et reconnaît la lettre comme tout un chacun, en plus de percevoir la couleur associée. La perception de l'inducteur reste primaire et fonctionnelle, tandis que le concurrent synesthésique s'y superpose ou l'accompagne [41, 40, 86].

Idiosyncrasie (Spécificité Individuelle) : Les associations synesthésiques sont intrinsèquement personnelles et spécifiques à chaque individu [41, 18, 74]. Cela signifie que les correspon-

dances établies entre l'inducteur et le concurrent (par exemple, quelle couleur est associée à une forme donnée) varient d'une personne à l'autre et sont uniques à son expérience perceptive. Bien que l'idiosyncrasie soit unanimement considérée comme une caractéristique clé, et soit souvent qualifiée d'*arbitraire* [41], ce terme doit être utilisé avec prudence et nuancé. Les associations sont uniques à l'individu (idiosyncratiques), mais ne sont pas nécessairement dénuées de logique interne ou totalement aléatoires. Elles peuvent en effet être influencées, par des facteurs développementaux, des expériences d'apprentissage spécifiques (comme l'exposition à des couleurs associées à des lettres dans l'enfance), la structure même de l'inducteur (comme la phonologie ou la sémantique des mots), ou des formes de synesthésie plus directement liées à la structure perceptive ou linguistique de l'inducteur (comme dans la synesthésie "Tinkertape") [66, 28, 74]. Plutôt qu'un aspect arbitraire total, l'accent est donc mis sur leur **idiosyncrasie** et leur **spécificité individuelle**. Cette spécificité est cruciale et est reflétée par la grande consistance observée lors des tests test-retest [56] : l'individu reproduit de manière fiable *ses propres* associations uniques au fil du temps, ce qui valide implicitement la nature personnelle de l'expérience.
Les termes *personnel*, *subjectif* ou *arbitraire* [41, 40] sont souvent associés à cette propriété, le dernier terme nécessitant une interprétation prudente compte tenu des nuances évoquées.

En synthèse, l'identification de la synesthésie en recherche repose principalement sur la mesure objective de l'automaticité et de la consistance des associations. Ces mesures sont complétées par la prise en compte des caractéristiques rapportées subjectivement ou inférées, comme l'additionnalité de l'expérience et la nature idiosyncratique et spécifique des associations. Comprendre ces critères est fondamental pour la distinguer d'autres phénomènes cognitifs, et explorer les hypothèses expliquant son origine, ce qui sera l'objet de la section suivante.

1.1.2 Théories Explicatives

Comprendre les mécanismes neuronaux et cognitifs sous-jacents à la synesthésie est un domaine de recherche actif et foisonnant. Plusieurs modèles théoriques ont été proposés, souvent complémentaires, reflétant probablement l'hétérogénéité du phénomène. Les recherches récentes continuent d'affiner notre compréhension en utilisant des techniques neuroscientifiques avancées [88, 62] et des approches génétiques [82].

Modèles Neurobiologiques

Plusieurs modèles neurobiologiques décrivent les mécanismes cérébraux expliquant comment l'information d'une modalité (inducteur) déclenche une expérience dans une autre (concurrent). La Figure 1.1 illustre schématiquement les principes fondamentaux de trois des modèles les plus influents, tels que décrits ci-après.

L'**activation croisée** (*cross-activation theory*), développée par Ramachandran et Hubbard [64, 39, 38], postule des connexions anatomiques directes et excessives entre aires cérébrales normalement distinctes mais adjacentes. Pour la synesthésie graphèmes-couleurs, cela impliquerait une hyper-connectivité entre le gyrus fusiforme (reconnaissance des graphèmes) et l'aire V4 (traitement de la couleur) [38]. Ce phénomène résulterait d'un défaut d'élagage synaptique (*pruning*) durant le développement, potentiellement génétique [82]. Des études structurelles (IRM, diffusion montrant une anisotropie fractionnelle accrue) [71, 34] et électrophysiologiques (EEG, MEG révélant des interactions rapides) [14, 10] soutiennent cette théorie, complétées par des recherches explorant les corrélats à l'échelle du cerveau entier [88, 62].

La **rétroaction désinhibée** (*disinhibited feedback theory*) [33, 56] propose une réduction de l'inhibition des rétroactions (*feedback*) des aires de convergence multisensorielles (pariétal, préfrontal) vers les aires sensorielles primaires. Chez les synesthètes, cette désinhibition permettrait une "fuite" anormale d'information entre modalités (ex : graphème/concept réactivant V4 pour la couleur), soulignant un déséquilibre fonctionnel (inhibition/excitation) plutôt que des

connexions anatomiques supplémentaires. L'IRMf a montré une connectivité fonctionnelle accrue, notamment du cortex pariétal [56, 72, 44]. Les modèles **réentrants**, impliquant des boucles de traitement descendant (*top-down*), sont également liés à cette approche [38, 30, 13].

Le plus récent concept de **résonance stochastique** [43] propose que des signaux faibles ou le "bruit" neuronal endogène soient amplifiés en perception consciente. Ce mécanisme est favorisé par une excitabilité neuronale accrue ou un déséquilibre inhibition/excitation, où un niveau optimal de bruit ou une dynamique neuronale spécifique facilite l'émergence des perceptions synesthésiques.

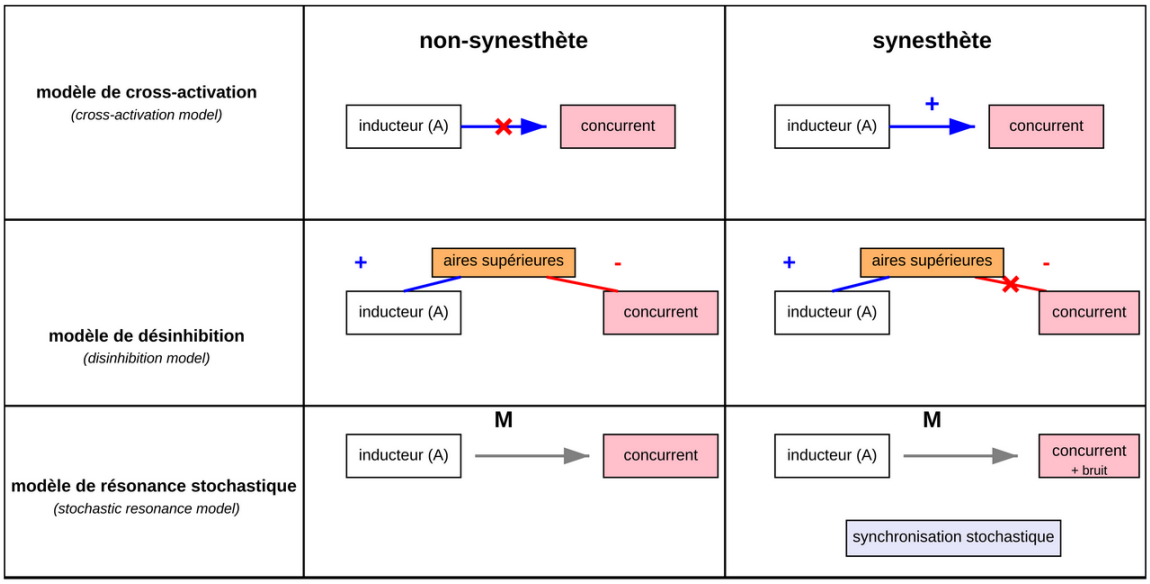


FIGURE 1.1 : **Modèles théoriques de la synesthésie chez les non-synesthètes et les synesthètes.** Cette figure compare les mécanismes proposés par trois modèles explicatifs principaux. Les éléments **inducteurs** (par exemple la lettre "A") activent ou interagissent avec les **concurrents** (par exemple la couleur rouge). Les flèches bleues indiquent des activations, les flèches rouges des interactions potentiellement inhibitrices, et les flèches grises des effets modulateurs ('M'). Selon le **modèle d'activation croisée** (ligne du haut), les synesthètes posséderaient des connexions additionnelles et actives entre l'inducteur et le concurrent, tandis que ces connexions seraient bloquées ou absentes chez les non-synesthètes (symbolisé par la croix rouge sur la flèche). Le **modèle de désinhibition** (ligne du milieu) suggère que chez les synesthètes, l'inhibition normale exercée par les "aires supérieures" sur le concurrent est réduite ou absente (croix rouge sur la flèche rouge d'inhibition), permettant ainsi au signal inducteur (via les aires supérieures) d'influencer le concurrent. Chez les non-synesthètes, cette inhibition est présente (flèche rouge avec la barre d'inhibition). Le **modèle de résonance stochastique** (ligne du bas) propose que les synesthètes présentent des niveaux de bruit plus élevés dans le concurrent (indiqué par "+ bruit"), ce qui, en présence de la modulation ('M') de l'inducteur, conduit à une synchronisation stochastique entre l'inducteur et le concurrent. Les liens sont gris pour souligner la nature modulatrice ou moins directe de l'interaction dans ce modèle.

Il est probable que ces différents types de mécanismes (activation croisée locale, rétroaction désinhibée via des régions de plus haut niveau, dynamique de résonance) ne soient pas mutuellement exclusifs et puissent coexister, voire expliquer différentes formes de synesthésie ou différents aspects du phénomène (par exemple, l'activation croisée pour les synesthètes "projectifs" et la rétroaction désinhibée pour les synesthètes "associatifs") [38, 72, 18].

Facteurs Cognitifs et Développementaux

Au-delà des mécanismes purement neuronaux d'activation ou de désinhibition, les facteurs cognitifs et développementaux jouent un rôle crucial dans la synesthésie. Comme nous souligné précédemment avec le concept d'**idéesthésie** [58], la signification extraite de l'inducteur est souvent le déclencheur principal de l'expérience synesthésique [58, 75]. Cela suggère que les processus sémantiques, la catégorisation et les réseaux conceptuels de haut niveau sont intimement liés au déclenchement, impliquant des réseaux neuronaux plus distribués [13].

Dans ce contexte cognitif et de développement, le rôle de l'**apprentissage** et de l'**expérience** dans la formation des associations synesthésiques spécifiques est également de plus en plus reconnu [90, 73, 29, 67]. Bien qu'une prédisposition génétique significative soit probable [3, 83, 82], les correspondances exactes (quelle couleur pour quelle lettre, par exemple) semblent souvent façonnées par des expériences précoces, telles que l'exposition à des associations culturelles ou des matériels pédagogiques colorés [90, 73]. Cela met en lumière une interaction complexe entre facteurs innés et acquis, renforcée par des études montrant qu'il est possible d'induire expérimentalement des associations synesthésiques (validées par les tests de Stroop et de consistance) chez des adultes non-synesthètes par un entraînement intensif [13, 70, 59]. Cette induction révèle une plasticité sous-jacente permettant l'établissement de telles connexions stables [82, 29, 67] et renforce l'idée que, au-delà de la prédisposition, l'apprentissage et les mécanismes cognitifs d'établissement de correspondances jouent un rôle formateur clé.

Comme souligné en introduction, la **théorie du vide sémantique**, illustrée en Figure 1.2, offre une approche intéressante pour expliquer l'émergence initiale et la consolidation de ces associations stables au cours du développement. Cette théorie suggère que la synesthésie pourrait résulter d'un déséquilibre développemental précoce entre la richesse des informations sensorielles perçues et la capacité limitée à les désigner, les nommer ou les catégoriser de manière abstraite [52, 58]. Cet écart - le "vide sémantique" - entre la perception brute et sa catégorisation émergente créerait une pression sur le système cognitif en développement, favorisant l'ancrage d'associations cross-modales stables pour aider à la désignation ou à la structuration des concepts. Les synesthètes pourraient ainsi utiliser ces liens sensoriels additionnels (comme associer une couleur constante à chaque lettre) pour consolider et distinguer des concepts (les lettres) qui sont encore en cours de formation ou dont la désignation explicite fait défaut au début de l'apprentissage.

Au terme de cette exploration de la synesthésie humaine, il ressort qu'elle résulte d'une interaction complexe entre une prédisposition neurodéveloppementale (potentiellement génétique, menant à une connectivité structurelle ou fonctionnelle atypique) et des facteurs environnementaux ou d'apprentissage qui façonnent les associations spécifiques chez l'individu. Les mécanismes précis peuvent ainsi varier, expliquant la diversité des formes synesthésiques observées. Les modèles explicatifs actuels tentent d'intégrer ces différents niveaux d'analyse, allant de mécanismes locaux d'activation croisée à des processus plus distribués impliquant des régions de haut niveau et des mécanismes de rétroaction, le concept d'**idéesthésie** soulignant notamment le rôle central du traitement cognitif et sémantique. Nous abordons maintenant comment des approches permettant d'explorer et modéliser l'intégration multimodale, nous dotant des outils pour essayer d'explorer le phénomène de la synesthésie d'un point de vue computationnel.

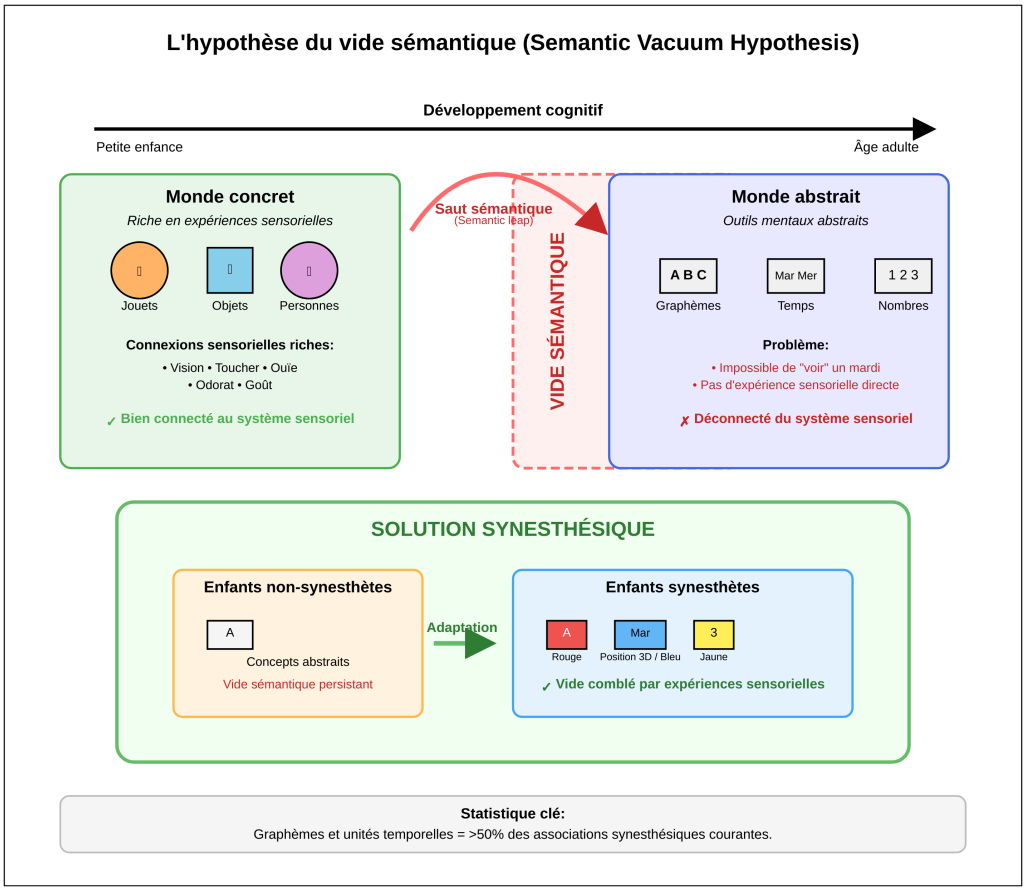


FIGURE 1.2 : L'hypothèse du vide sémantique en synesthésie. La figure illustre la transition développementale du monde concret (expériences sensorielles directes) au monde abstrait (concepts mentaux comme les graphèmes). Le "vide sémantique" représente la difficulté à lier ces abstractions à des référents. Chez les non-synesthètes, ce vide peut persister. Chez les synesthètes, une "solution synesthésique" émerge : des associations sensorielles (ex : couleur-lettre) ancrent les concepts abstraits, comblant le vide. La prévalence des associations graphèmes/unités temporelles (>50%) soutient cette théorie.

1.2 Modéliser l'intégration multimodale

Cette section aborde la question fondamentale de la **modélisation de l'intégration multimodale**. Pour y répondre, nous explorerons d'abord les défis et les mécanismes inhérents à l'intégration multimodale du **point de vue informatique et pratique**. L'objectif est ici de comprendre comment les systèmes d'apprentissage multimodaux parviennent à traiter et à associer des informations hétérogènes, menant au développement d'**outils** concrets (Section 1.2.1). Ensuite, nous nous tournerons vers une approche **bio-inspirée**, en présentant la Théorie du Global Workspace (GWT). Cette perspective issue des neurosciences cognitives offre un cadre théorique pour comprendre comment l'intégration d'informations se manifeste dans le cerveau, et vise à l'élaboration de **modèles** explicatifs de la cognition (Section 1.2.2). Enfin, nous présenterons comment notre travail essaye de **combiner le meilleur de ces deux mondes**. Nous décrirons l'architecture du modèle que nous utilisons, qui s'inspire directement des principes de la GWT tout en s'appuyant sur des techniques d'apprentissage profond pour explorer les conditions d'émergence de phénomènes d'intégration inter-modale potentiellement analogues à la synesthésie artificielle (Section 1.2.3).

1.2.1 Mécanismes Clés de l'Intégration Multimodale en Apprentissage Profond

Les mécanismes de l'intégration multimodale en apprentissage profond, s'articulent autour de plusieurs problématiques fondamentales, visant à rapprocher et faire interagir différentes modalités :

- **Représentation :** Le défi initial en IA multimodale est de **représenter** des données de natures très diverses (ex : visuelle, textuelle, auditive) de manière unifiée ou inter-compatible [6]. L'objectif est de transformer ces signaux bruts en descriptions numériques qui capturent non seulement les propriétés spécifiques à chaque modalité, mais aussi les relations entre elles. Les approches contemporaines apprennent soit des **représentations conjointes**, fusionnant l'information des différentes modalités dans un unique espace d'embedding, soit des **représentations coordonnées**, où les modalités sont encodées séparément mais dans des espaces alignés facilitant la comparaison et l'interaction. Une direction clé récente est celle des **Grands Modèles de Langage Multimodaux (MLLMs)** [1]. Ces modèles s'appuient sur des LLMs en intégrant les informations provenant d'autres modalités, qui sont typiquement transformées en un format compatible avec le traitement par le LLM (par exemple, des séquences de tokens discrets ou d'embeddings continus). L'architecture du LLM sert alors de mécanisme d'intégration central, traitant conjointement ces informations multimodales et le texte. Il en résulte des **représentations internes unifiées** qui lient intrinsèquement les données de différentes modalités et capitalisent sur la vaste connaissance sémantique pré-existante du LLM. Ces représentations constituent la base computationnelle essentielle pour les étapes ultérieures de liaison et d'intégration multimodale.

- **Alignement :** Il s'agit d'identifier et d'établir les correspondances fines entre des éléments (ou sous-éléments) de différentes modalités [6]. Les approches de pointe intègrent souvent l'alignement de manière **implicite**, notamment via les mécanismes d'**attention croisée** (*cross-attention*) dans les architectures neuronales [5, 48]. Ces mécanismes permettent à un modèle de "prêter attention" dynamiquement aux parties pertinentes d'une autre modalité lorsqu'il traite une information, facilitant ainsi l'intégration et la focalisation [48]. Des modèles comme ViLBERT [48] ou Flamingo [1] illustrent l'efficacité de l'attention croisée pour aligner des mots avec des régions d'image.

- **Fusion :** Le défi de la fusion consiste à agréger de manière cohérente les informations provenant de différentes modalités afin de générer une représentation unifiée pouvant déboucher à une décision ou une prédiction. [6]. Selon le stade où l'intégration s'opère, on distingue classiquement la fusion précoce (au niveau des caractéristiques brutes), la fusion tardive (au niveau des décisions unimodales) et la fusion intermédiaire (au sein du modèle d'apprentissage) [46, 6]. Les **architectures basées sur des modèles**, notamment les réseaux neuronaux profonds, sont particulièrement adaptées à la **fusion intermédiaire**, car elles permettent d'apprendre des interactions complexes en combinant les représentations latentes des modalités au sein de leurs couches cachées [6, 57].

- **Co-apprentissage :** Cette problématique exploite les informations d'une modalité pour améliorer l'apprentissage dans une autre, particulièrement utile lorsque l'une des modalités est pauvre en ressources annotées. Les représentations coordonnées apprises par des modèles comme **CLIP** [63] facilitent le transfert de connaissances, permettant des applications de **Zero-Shot Learning** où un modèle peut reconnaître des objets visuels non vus pendant l'entraînement en s'appuyant sur leur description textuelle associée via l'espace d'embedding partagé [31, 61]. Les techniques de co-entraînement [11] sur des données parallèles ou le **conceptual grounding** (ancrer des concepts linguistiques dans des expériences sensorielles [9, 17]) illustrent également comment la liaison multimodale peut enrichir l'apprentissage d'une modalité par les connaissances d'une autre.

- **Traduction et gestion de l'asymétrie :** Comment peut on traduire l'information d'une modalité à une autre ? Il n'y a souvent pas une correspondance parfaite entre les informations, ce qui implique de gérer les redondances et les **gaps informationnels**, situations où une modalité ne capture pas entièrement l'information véhiculée par une autre [42]. La littérature récente révèle que forcer un alignement parfait entre modalités peut paradoxalement nuire aux performances en éliminant des signaux modaux spécifiques [42]. Face à ces asymétries, plusieurs stratégies ont émergé : l'imputation cross-modale génère directement l'information manquante (par exemple, Hoffman et al. [36] "hallucinent" des caractéristiques de profondeur à partir d'images RGB), et l'**alignement par attention croisée** permet aux modèles de compenser les lacunes en focalisant sur les éléments pertinents des autres modalités [81].

L'ensemble de ces problématiques mène au développement d'approches où des données hétérogènes sont transformées en représentations compatibles, alignées, fusionnées, traduites ou utilisées pour un apprentissage mutuel. Ces capacités de liaison s'incarnent fréquemment dans des architectures **modulaires**, composées de sous-réseaux spécialisés pour chaque modalité interagissant via des espaces partagés et des mécanismes d'attentions. Ces architectures et leurs dynamiques, évoquant la GWT, ont naturellement conduit à un rapprochement conceptuel [84].

1.2.2 La Théorie du Global Workspace : Une Inspiration Bio-cognitive

Comment notre cerveau résout-il le problème de l'intégration multimodale ? La GWT, proposée initialement par Bernard Baars [4] et enrichie dans un cadre neuroscientifique par Stanislas Dehaene et Jean-Pierre Changeux [23], offre un cadre conceptuel pertinent pour comprendre l'intégration d'informations multimodales dans le cerveau.

Principes Fondamentaux de la GWT

La GWT propose que l'information, traitée par des modules cérébraux spécialisés et souvent inconscients, peut devenir globalement accessible et être intégrée pour donner lieu à la cognition consciente et aux fonctions exécutives supérieures. L'idée centrale est celle d'un espace de travail global (le GW) de capacité limitée, vers lequel des informations saillantes sont diffusées ("broadcastées") par les modules spécialisés qui entrent en compétition pour y accéder. Une fois dans cet espace global, l'information est disponible pour une multitude d'autres modules spécialisés, permettant ainsi une large diffusion et une intégration des connaissances nécessaires à la planification, à la prise de décision et à la génération de réponses comportementales adaptées. C'est cette accessibilité globale de l'information qui serait au coeur de l'expérience consciente selon cette théorie [23].

Modèles Computationnels Inspirés de la GWT

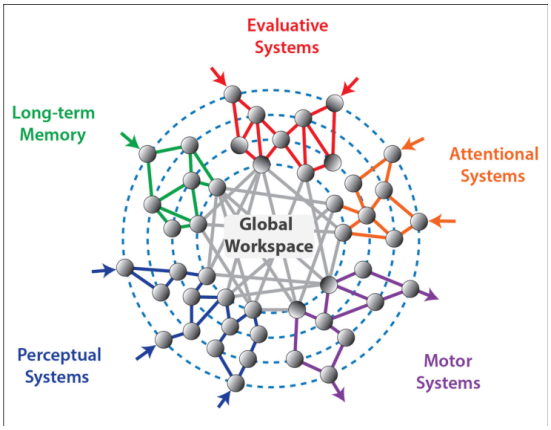
La GWT a inspiré de nombreux modèles computationnels cherchant à simuler ses principes, allant de modèles symboliques abstraits aux réseaux de neurones artificiels. Ces implémentations se déclinent en trois catégories principales :

Modèles neuroscientifiques : Les modèles orientés neurosciences computationnelles simulent les dynamiques neuronales de la GWT. Le modèle Global Neuronal Workspace de Dehaene et Changeux [23] constitue une référence pionnière, utilisant des réseaux neuronaux pour simuler les interactions corticales à grande échelle et analyser l'accès conscient.

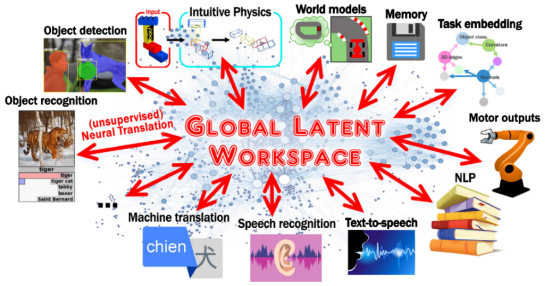
Applications en apprentissage profond : Certains travaux appliquent les principes GWT pour améliorer les performances d'IA sur des tâches complexes, notamment dans les architectures Transformers pour le raisonnement séquentiel ou l'intégration de modules de mémoire partagés [37].

Architectures GW natives : Ces modèles implémentent explicitement l'architecture modulaire avec un canal central d'échange d'information. Goyal et al. [32] ont démontré qu'une communication centralisée et compétitive via un espace partagé améliore la coordination des modules par rapport à l'attention *pair-wise* traditionnelle.

Ces approches illustrent la pertinence croissante de la GWT pour structurer l'intégration d'information complexe dans les architectures d'IA. La **Figure 1.3** compare la théorie cognitive (a) aux implémentations en apprentissage profond (b), suivant les travaux de Van Rullen & Kanai [84] sur les modèles multimodaux inspirés de la GWT. Ouvrant une nouvelle fenêtre de recherche en apprentissage multimodal profond [19, 50, 24].



(a) Schéma conceptuel de la GWT. Des modules spécialisés diffusent l'information saillante vers un espace de travail global central, la rendant accessible à d'autres modules pour une intégration et une cognition consciente.



(b) Inspiration d'architecture d'IA inspirée de la GWT proposée par VanRullen & Kanai (2021). Des encodeurs traitent les modalités, projettent l'information dans un espace latent central, d'où les décodeurs peuvent la lire pour diverses tâches.

FIGURE 1.3 : Illustrations de la GWT et d'une proposition de son adaptation dans un contexte d'apprentissage profond.

1.2.3 Notre Modèle Inspiré de la GWT : Architecture et Apprentissage

En combinant les approches informatiques et bio-inspirées, nous proposons d'utiliser une architecture qui répond aux défis techniques de l'intégration multimodale tout en s'inspirant des principes organisationnels de la GWT. Pour cela nous utilisons comme outil le modèle développé par VanRullen, Maytié et Devillers [84, 24].

Ce modèle est explicitement conçu autour des principes de la GWT pour structurer le traitement et l'intégration d'informations provenant de différentes modalités, fournissant ainsi un cadre adapté à notre investigation.

Son architecture est modulaire : des encodeurs et décodeurs spécialisés pour chaque modalité sont connectés à un **espace central latent partagé** : le GW artificiel, agissant comme un carrefour où l'information traitée par les modules unimodaux **gagne un accès global** et peut ainsi influencer les autres modalités. Cette dynamique d'accès et de diffusion simule l'intégration et la communication entre aires cérébrales spécialisées postulées par la GWT.

Par conséquent, cette structure architecturale visant à simuler la dynamique de diffusion et d'intégration d'informations via un espace central de disponibilité globale rend ce modèle particulièrement pertinent pour étudier comment des liens inter-modaux, analogues à la synesthésie, peuvent émerger de tels mécanismes d'intégration inspirés de la GWT. Nous illustrons un

exemple générique de ce modèle en Figure 1.4 **A**.

L'apprentissage du modèle est structuré par la minimisation d'une combinaison pondérée de quatre *losses* (fonctions de perte) (cf fig. 1.4 **B**). Ces *losses* guident l'apprentissage des encodeurs/décodeurs et la structuration de l'espace du GW.

Le principe de ces *losses* est le suivant :
Les *losses* **supervisées**, nécessitant des **données multimodales appariées** :

- La ***loss* de Traduction** (*Translation Loss*) : Mesure la capacité du modèle à reconstruire fidèlement une modalité à partir de la représentation dans le GW obtenue de l'autre modalité, assurant ainsi l'inter-traduisibilité de l'information via l'espace partagé (Modalité A $\rightarrow$ GW $\rightarrow$ Modalité B).
- La ***loss* Contrastive** (*Contrastive Loss*) : Vise à aligner les représentations des différentes modalités dans l'espace latent du GW, en rendant les représentations d'exemples correspondants plus similaires que celles d'exemples non correspondants.

Les *losses* **auto-supervisées** (ou non-supervisées), ne nécessitant **pas de données multimodales appariées** :

- La ***loss* de Demi-Cycle** (*Half-Cycle Loss*) : Mesure la fidélité de la reconstruction d'une modalité après un aller-retour via le GW intra-modalité (Modalité A $\rightarrow$ GW $\rightarrow$ Modalité A), s'assurant que l'information originale est préservée pour permettre une reconstruction intra-modale fidèle.
- La ***loss* de Cycle-Complet** (*Full-Cycle Loss*) : Mesure la capacité du modèle à reconstruire fidèlement la modalité d'entrée après un cycle-complet de transformation passant par l'autre modalité via le GW (Modalité A $\rightarrow$ GW $\rightarrow$ Modalité B $\rightarrow$ GW $\rightarrow$ Modalité A). Cette *loss* sera particulièrement pertinente pour encourager l'encodage implicite d'informations transitant indirectement.

La *loss* contrastive vise à aligner directement les représentations des différentes modalités dans le GW en se basant sur leur similarité encodée (similaire à la *loss* utilisée dans CLIP [63]). Les autres *losses* (Traduction, Demi-Cycle, Cycle-Complet) sont basées sur la fidélité de reconstructions en comparant une sortie du modèle à la "vérité terrain" (*ground truth*) de la modalité correspondante.

Elles se distinguent par le chemin de propagation de l'information suivi pour obtenir cette reconstruction. La minimisation de chacune de ces *losses* rétropropage une erreur spécifique, influençant ainsi différemment l'ajustement des poids des encodeurs/décodeurs du GW en fonction de leur contribution au chemin concerné.

Cette approche d'apprentissage semi-supervisé (combinant *losses* supervisées et non-supervisées) permet au système non seulement d'apprendre des représentations multimodales avec moins de données appariées, mais aussi de simuler la dynamique d'intégration de l'information entre modules spécialisés telle que postulée par la GWT. Ceci rend ce dernier particulièrement pertinent pour notre investigation sur l'émergence de la synesthésie artificielle. Les détails précis de l'implémentation technique, du jeu de données utilisé, du protocole d'entraînement et des méthodes d'évaluation sont présentés dans le Chapitre 2.

1.3 Vers une Synesthésie Artificielle

Pour évaluer si des phénomènes d'association cognitive similaires à la synesthésie peuvent émerger artificiellement dans des systèmes d'apprentissage profond. Il est d'abord nécessaire de les

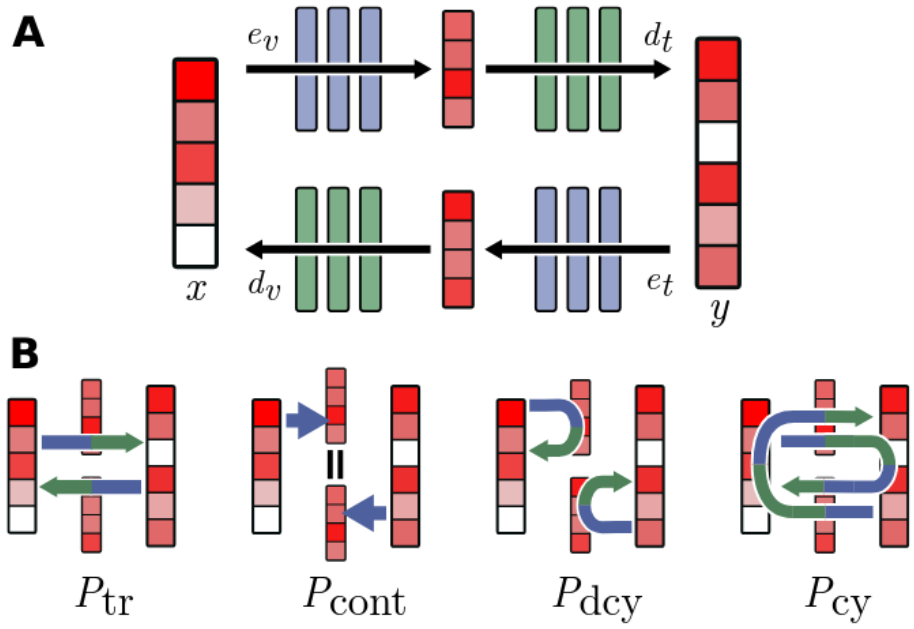


FIGURE 1.4 : **A** : Réseau bimodal générique tel que proposé par [24]. Les entrées peuvent provenir de deux modalités x et y (dans notre cas, des images visuelles et des vecteurs d'attributs). e_v et e_t sont des réseaux de neurones *feed-forward* qui projettent chaque modalité dans un espace latent ; d_v et d_t sont des décodeurs qui décodent l'espace latent vers la modalité respective. **B** : Illustration des *losses* supervisées de traduction (*Translation Loss*, P_{Tr}) et contrastive (*Contrastive Loss*, P_{cont}), ainsi que des *losses* non-supervisées de demi-cycle (*Half-Cycle Loss*, P_{dcy}) et de cycle-complet (*Full-Cycle Loss*, P_{cy}). Chaque flèche sur ces schémas indique le chemin sur lequel la *loss* associée est rétropropagée afin d'ajuster les poids du réseau.

définir. Notre but n'est pas de simuler l'expérience consciente d'un synesthète, mais d'identifier des signatures fonctionnelles présentant des analogies structurelles avec les caractéristiques observables de la synesthésie humaine.

1.3.1 Limites des Approches Existantes et Justification de la Définition

À notre connaissance, la seule étude présentant une ambition de modéliser une synesthésie dans un modèle d'apprentissage profond, est celle de Bock [12]. Cette étude démontre qu'un réseau neuronal peut apprendre et reproduire la stabilité d'associations synesthésiques typiques (observées au niveau d'une population) en s'entraînant sur des données présentant ces corrélations. Cependant, cette approche modélise l'apprentissage de régularités existantes et n'explore pas la capacité d'un système à développer *ses propres* correspondances stables et spécifiques, non imposées par les corrélations fortes ou fréquentes de l'environnement. C'est précisément cette capacité d'émergence de liens inter-modaux stables et spécifiques à une instance d'apprentissage – qui ne sont pas trivialement dictés par la structure statistique externe des données – qui constitue la lacune et la nouveauté explorée par cette recherche.

Pour combler cette lacune et permettre une évaluation rigoureuse de l'émergence d'un tel phénomène artificiel, nous avons cherché à en donner une première définition.

1.3.2 Définition de la Synesthésie Artificielle

Nous définissons la **synesthésie artificielle** comme :

l'émergence au sein du modèle d'associations stables (régulières) et spécifiques à l'instance d'entraînement (arbitraires) entre une caractéristique x d'une modalité de traitement (jouant le

rôle d'inducteur artificiel) et une modalité y (jouant le rôle de concurrent artificiel), sans que cette association ne soit explicitement encodée dans les données d'entraînement ou directement forcée par l'architecture du modèle de manière universelle ; ni que cette émergence ne nuise à la capacité du modèle à réaliser ses tâches principales de traitement multimodal.

Cette définition est construite en miroir des caractéristiques clés de la synesthésie humaine décrite en Section 1.1.1, adaptée pour le contexte computationnel :

- **Régularité (Consistance)** : Pour un inducteur artificiel donné, et pour une instance d'entraînement particulière, le modèle doit générer de manière fiable et répétée une **expérience ou output stable du concurrent artificiel** (ex : une couleur), au cours de multiples inférences ou sessions d'évaluation. Cela traduit la stabilité temporelle humaine par une régularité fonctionnelle intra-instance.
- **Arbitraire (Idiosyncrasie / Spécificité Individuelle)** : Bien que régulières pour une même instance d'entraînement, ces associations doivent être **spécifiques à l'instance** et varier de manière non prédictible entre différentes instances. Cette variabilité inter-instance, couplée à la stabilité intra-instance, est fondamentale pour refléter la non-trivialité des associations synesthésiques humaines.
- **Additionnalité** : L'association synesthésique doit préserver le traitement normal de l'information à la disposition du modèle.

L'**automaticité**, bien qu'essentielle en synesthésie humaine, est considérée comme une propriété inhérente aux mécanismes d'activation des architectures d'apprentissage profond et ne nécessite, à notre sens, pas d'évaluation distincte dans ce cadre.

Ceci posé, nous pouvons maintenant préciser le cadre de notre problématique, l'enjeu principal étant de faire émerger des associations satisfaisant à ces critères dans notre modèle.

1.3.3 Synthèse et positionnement de la problématique

Pour aborder cette question, nous nous inspirons de la **théorie du vide sémantique**. Cette théorie postule que les associations synesthésiques émergent d'une asymétrie informationnelle, où un concept abstrait s'ancre à une expérience sensorielle pour combler un manque d'information, comme le suggère l'influence des matériels pédagogiques colorés sur les associations graphèmes-couleurs humaines [90]. C'est cette dynamique d'asymétrie fondamentale que nous nous proposons de reproduire au sein de notre modèle d'IA, conçu avec une architecture inspirée de la GWT.
Spécifiquement, la modalité 'attributs' représentera la catégorisation conceptuelle abstraite (analogue aux lettres ou chiffres, et délibérément dépourvue de l'information de couleur explicite), tandis que la modalité 'visuelle' (en particulier sa composante couleur) correspondra à l'aspect perceptif sensoriel. Cette omission délibérée de l'information de couleur dans la modalité 'attributs' vise à créer artificiellement un "vide sémantique" — une situation où le système est contraint d'établir des ponts entre une représentation conceptuelle incomplète et une information sensorielle riche.
Dans ce contexte théorique et computationnel, notre **problématique de recherche principale** est la suivante :

Dans quelle mesure et sous quelles conditions d'apprentissage (notamment l'introduction d'asymétrie informationnelle et la pondération des objectifs d'entraînement) un modèle d'apprentissage profond inspiré de la GWT peut-il développer des correspondances stables et spécifiques entre des représentations issues de modalités artificielles distinctes, sans qu'elles supplantent la vérité terrain, manifestant ainsi une forme de "synesthésie artificielle", et comment cette émergence est-elle façonnée par les mécanismes d'intégration du Global Workspace ?

Chapitre 2

Méthodologie

Ce chapitre décrit la méthodologie mise en œuvre pour examiner les conditions d'émergence de la synesthésie artificielle au sein d'un modèle computationnel inspiré de la GWT, en testant notre hypothèse clé : une asymétrie informationnelle contrôlée lors de l'apprentissage multimodal peut induire l'établissement d'associations stables et arbitraires entre modalités artificielles.

Notre démarche méthodologique s'articule autour de trois composantes interdépendantes : (1) la construction d'un environnement expérimental contrôlé via un corpus de données synthétiques permettant la manipulation précise des relations intermodales, (2) l'implémentation d'une architecture computationnelle modulaire capable d'intégrer différentes modalités via un espace latent partagé, et (3) l'opérationnalisation de critères d'évaluation objectifs traduisant les signatures comportementales de la synesthésie humaine en métriques computationnelles quantifiables.

Ce chapitre détaille ces trois piliers : Section 2.1 présente le jeu de données et l'introduction de l'asymétrie informationnelle. Section 2.2 décrit l'architecture du modèle GWT et les conditions d'entraînement explorées. Enfin, Section 2.3 explicite les critères d'évaluation quantitative développés.

2.1 Données Utilisées

Notre étude repose sur le *Simple Shapes Dataset* (SSD) [24], un corpus de données synthétiques généré de manière procédurale. Initialement conçu pour des expériences contrôlées en apprentissage multimodal, le SSD offre une grande flexibilité en termes de taille et de distribution des attributs. Il est intrinsèquement multimodal, associant des données visuelles (images d'objets simples) à des vecteurs d'attributs numériques correspondants. Pour nos expériences, nous avons utilisé une version standard du SSD pour l'entraînement du modèle et avons conçu un jeu de données de test spécifique, structuré pour évaluer l'émergence de la synesthésie artificielle.

2.1.1 Jeu de Données d'Entraînement (SSD Standard)

Le jeu de données d'entraînement est constitué de 500 000 paires image-attributs. Chaque paire représente un objet unique, caractérisé par ses propriétés visuelles et un vecteur d'attributs descriptifs. La Figure 2.1 illustre une telle paire.

Modalité Visuelle (Images)

Chaque image d'entraînement est une image de 32×32 pixels avec un fond noir, contenant un unique objet simple. Cet objet est défini par les attributs suivants, dont les valeurs sont échantillonnées uniformément dans leurs plages respectives pour chaque image générée, assurant ainsi une distribution homogène des caractéristiques :

- **Forme :** L'une des trois suivantes : oeuf, triangle isocèle, ou diamant.
- **Taille :** Une valeur continue (rayon ou demi-largeur entre 7 et 14 pixels).

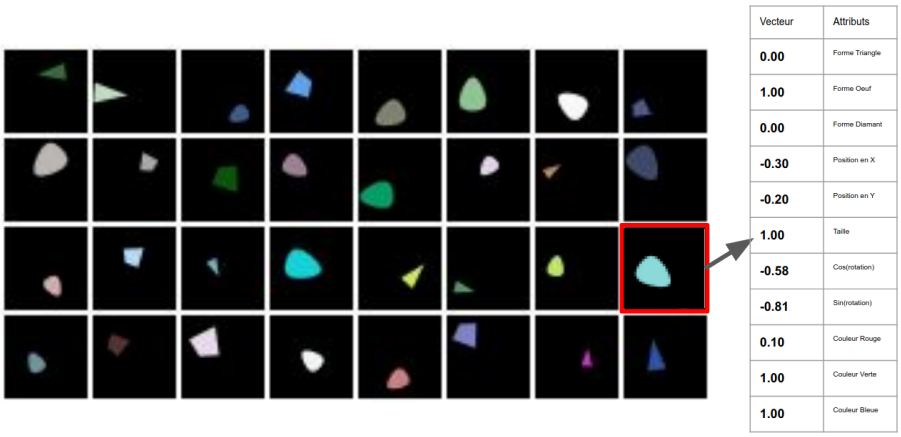


FIGURE 2.1 : Illustration du *Simple Shapes Dataset* (SSD) utilisé dans cette étude. **À gauche :** Un aperçu de la diversité visuelle du jeu de données, montrant de multiples instances d'objets (oeufs, triangles, diamants) variant en forme, taille, position, orientation et couleur, sur un fond noir. **À droite :** Le vecteur d'attributs numériques (normalisés) correspondant à l'instance visuelle mise en évidence par un cadre rouge. Ce vecteur encode de manière quantitative les caractéristiques de l'objet sélectionné

- **Position (x, y) :** Coordonnées continues ($x, y \in [8, 24]$ pixels) centrant l'objet.
- **Orientation (angle) :** Une valeur continue (entre 0 et 2π radians).
- **Couleur (RGB) :** Trois valeurs continues (Rouge, Vert, Bleu, entre 0 et 255 pour chaque canal).

Modalité des Attributs (Vecteurs Numériques)

À chaque image est associé un vecteur numérique qui représente ses attributs de manière symbolique. Pour le jeu de données d'entraînement, ce vecteur encode l'ensemble des propriétés de l'objet :

- Forme (encodage one-hot : [1,0,0] pour triangle, [0,1,0] pour oeuf, [0,0,1] pour diamant).
- Taille (valeur normalisée).
- Position x, y (valeurs normalisées).
- Orientation (encodée en sin/cos de l'angle pour gérer la circularité).
- Couleur (valeurs R, G, B normalisées).

Les valeurs continues sont normalisées (entre -1 et 1) avant d'être utilisées par le modèle.

2.1.2 Jeu de Données de Test (Structuré pour l'Évaluation Synesthésique)

Contrairement au jeu d'entraînement où les attributs sont échantillonnés aléatoirement, le jeu de test est généré de manière systématique pour permettre une évaluation quantitative et contrôlée de l'émergence de la synesthésie artificielle. Il est conçu pour présenter au modèle des combinaisons d'attributs spécifiques et évaluer les critères de **régularité** et d'**arbitraire** des couleurs reconstruites.

Combinaisons d'Attributs Non-Couleur

Nous avons d'abord défini un ensemble de combinaisons uniques d'attributs "non-couleur" en fixant des valeurs discrètes pour chaque attribut :

- **Forme :** Les 3 formes possibles (oeuf, triangle isocèle, diamant).
- **Taille :** 8 valeurs distinctes, échantillonnées linéairement (de 7 et 14 pixels).
- **Position (x, y) :** 16 positions fixes, résultant de la combinaison de 4 valeurs discrètes pour l'axe x et 4 valeurs pour l'axe y.
- **Orientation :** 16 orientations fixes, échantillonnées avec un pas régulier de $\pi/8$ radians entre 0 et $15\pi/8$.

La combinaison de ces valeurs produit $3 \times 8 \times 16 \times 16 = 6144$ combinaisons uniques d'attributs non-couleur.

Variations de Couleur Systématiques

Pour chaque combinaison d'attributs non-couleur, 25 images sont générées. Chaque image reçoit une couleur distincte et fixe, définie systématiquement via le modèle Teinte-Saturation-Luminosité (HSL). Ce modèle (cf. Figure C.1), choisi pour sa meilleure adéquation avec la perception humaine que le RGB, permet une analyse intuitive de la teinte en une seule dimension.

Nous avons utilisé les paramètres suivants :

- **Teinte (Hue) :** 25 valeurs discrètes, linéairement espacées de 0 à ≈ 360 degrés (par pas de 14.4°), pour couvrir le cercle chromatique.
- **Saturation (S) :** Constante et élevée (S ≈ 0.90).
- **Luminosité (L) :** Constante et élevée (L ≈ 0.70).

Ces valeurs HLS, assurant des couleurs vives et distinctes du fond noir, sont ensuite converties en RGB pour la génération des pixels. Cette méthode garantit un ensemble de test de couleurs identique et prédéfini pour chaque condition non-couleur, permettant d'isoler l'influence de ces attributs sur la couleur reconstruite.

Composition Finale du Jeu de Test

Le jeu de test final est donc constitué de 6144 (combinaisons non-couleur)$\times$25 (variations de teinte), soit 153 600 paires image-attributs uniques. Chaque vecteur d'attributs du jeu de test est construit de la même manière que pour l'entraînement (forme en one-hot, autres valeurs normalisées).

2.1.3 Pertinence pour l'Étude

Le SSD, avec la distinction entre un jeu d'entraînement à large couverture aléatoire et un jeu de test systématique, est particulièrement adapté à notre recherche. La nature synthétique du SSD permet un contrôle précis des relations intermodales et des informations présentées au modèle. L'échantillonnage uniforme des attributs dans le jeu d'entraînement assure une bonne exploration de l'espace des caractéristiques. Plus important encore, la structure du jeu de test, avec sa variation systématique de couleur pour des combinaisons fixes d'attributs non-couleur, est spécifiquement pensée pour évaluer si un attribut non-couleur donné (par exemple, une forme spécifique) induit une réponse couleur stable et potentiellement spécifique à l'instance du modèle.

2.2 Architecture et Spécificités Implémentatoires du modèle

2.2.1 Fondements architecturaux

L'architecture computationnelle déployée dans cette étude est une implémentation du modèle décrit par Devillers et al. [24], dont le principe a été introduit en Section 1.2.3. Ce modèle modulaire est conçu pour l'intégration multimodale via un espace latent partagé central qui fait office de GW.

Le modèle traite deux modalités principales : l'image (visuelle) et le vecteur d'attributs (symbolique). La modalité visuelle utilise un autoencodeur variationnel (VAE) pré-entraîné [24] dont les poids sont "gelés" pendant l'entraînement, servant de représentation visuelle latente de dimension 12. La modalité attributs reçoit directement le vecteur d'attributs en entrée.

2.2.2 Conditions expérimentales et vide sémantique

Pour explorer notre problématique de recherche et évaluer l'impact d'une asymétrie informationnelle, nous avons investigué deux conditions d'entraînement principales :

- **Modèles Complets** : Le vecteur d'attributs inclut l'information complète sur la couleur (valeurs R, G, B normalisées). Les deux modalités ont un accès direct et symétrique à l'information de couleur, servant de **condition de contrôle**.
- **Modèles avec Vide Sémantique** : L'information de couleur est **intentionnellement omise** du vecteur d'attributs durant l'entraînement. La modalité visuelle conserve son accès à la couleur via les pixels, mais la modalité des attributs est "aveugle" à la couleur. C'est sur ces modèles que nous testons l'hypothèse d'émergence de synesthésie artificielle induite par l'asymétrie informationnelle.

2.2.3 Paramétrage technique

Les encodeurs modaux projettent leurs représentations d'entrée (visuelle latente ou attributs) vers un espace d'interface de dimension 12 : le GW. Chaque encodeur/décodeur est un *multi-layer perceptron* (MLP) comprenant une couche d'entrée de taille 12, suivie de quatre couches cachées de taille 256, puis d'une couche de sortie de taille 12 donnant sur le GW.
La *loss* totale est $L_{total} = \frac{1}{S}(\alpha L_{translation} + \beta L_{contrastive} + \gamma L_{half-cycle} + \delta L_{full-cycle})$ où $S = \alpha + \beta + \gamma + \delta$ est la somme des coefficients. La descente de gradient est réalisée via l'optimiseur AdamW , particulièrement efficace pour les tâches de classification d'images [47].
Le taux d'apprentissage est géré par la politique OneCycleLR [80], avec un taux maximal initial de 2.6×10^{-5} décroissant jusqu'à 2×10^{-6} en fin d'entraînement.
Le modèle est entraîné pendant 300 000 *epochs* (itérations sur le jeu de données d'entraînement), avec une taille de *batch* (nombre d'exemples traités simultanément avant la mise à jour des poids) de 2056 échantillons . Les poids des encodeurs et décodeurs sont initialisés selon l'algorithme Kaiming [35].

2.3 Operationalisation des Critères et Méthodes d'Évaluation

Pour évaluer la synesthésie artificielle (associations régulières, arbitraires, additionnelles, cf. Section 1.3.2), nous analysons les liens entre un attribut (inducteur) et sa couleur reconstruite (concurrent). Notre méthodologie repose sur l'analyse quantitative des distributions de couleurs extraites des images générées par le modèle via divers chemins de transformation, simulant la circulation de l'information. Pour chaque catégorie de chaque attribut binné (forme, taille, position X, position Y, orientation) et chaque voie de traitement pertinente, nous procédons en plusieurs étapes.

2.3.1 Extraction et Analyse des Distributions de Couleurs

Extraction de la Couleur de la Forme Reconstruite

Les images produites par les modèles sont d'abord analysées pour segmenter la forme de son fond noir. Un masque binaire de la forme est obtenu par application d'un seuillage d'Otsu (masque défini de manière à maximiser la variance entre ce qu'il contient et ce qu'il exclut) sur l'image en niveaux de gris.
La couleur caractéristique de la forme est ensuite extraite de l'image originale ou reconstruite en utilisant la valeur moyenne d'une petite aire de 3 pixels centrée sur barycentre de l'aire définie par le masque obtenu. Cela permet d'obtenir une mesure de couleur robuste qui réduit l'influence de la géométrie spécifique ou des artéfacts de bord de la forme.

Constitution des Distributions de Couleurs Reconstruites

Pour l'analyse, nous regroupons les images générées par le modèle en fonction de leurs attributs non-couleur (forme, taille, position, orientation) tels que définis dans le jeu de test. L'attribut 'forme' est intrinsèquement catégoriel (3 formes). Pour les attributs continus (taille, position, orientation), dont les valeurs sont fixées et linéairement espacées dans le jeu de test (*cf.* Section 2.1.2), chaque valeur spécifique utilisée est considérée comme une catégorie distincte pour l'analyse. L'espacement linéaire assure que ces valeurs représentent des points bien différenciés dans l'espace des attributs, permettant une analyse par catégorie pertinente.

L'ensemble des couleurs ainsi extraites pour chaque catégorie d'attribut constitue la distribution de couleurs que nous analysons. Pour l'analyse statistique, ces distributions sont discrétisées en 15 intervalles (*bins*) de taille égale pour chaque canal de couleur utilisé (Hue, Rouge, Vert, Bleu).

2.3.2 Application des Critères d'Identification

Les critères de régularité et d'arbitraire sont appliqués aux distributions de couleurs discrétisées pour identifier l'émergence de la synesthésie artificielle.

Critère d'Additionnalité

Ce critère garantit que les associations synesthésiques émergentes préservent les capacités fondamentales du modèle en traitement visuel et catégoriel.

Méthode : Évaluation qualitative des performances des Modèles avec Vide Sémantique vérifiant :

a) **Fidélité des attributs non-couleur :** Le modèle restitue correctement forme, taille, position et orientation lors de la génération d'images à partir d'attributs.

b) **Préservation du traitement couleur par le GW :** Capacité du GW à traiter fidèlement l'information couleur provenant de la modalité visuelle, évaluée par la reconstruction chromatique correcte après un demi-cycle purement visuel (Image $\rightarrow$ GW $\rightarrow$ Image). Cette fonction sert de *proxy* au maintien de l'ancrage perceptif réel, analogue à la capacité d'un synesthète humain à distinguer couleurs réelles et synesthésiques.

Critère de Validation : Le critère est jugé satisfait pour un modèle s'il respecte les points a) et b) ci-dessus. Cette approche, qualitative par manque de temps dans le cadre de cette étude, vise une quantification rigoureuse (ex : SSIM[85], seuillage de la *loss* de reconstruction) dans de futurs travaux.

Critère de Régularité

Ce critère évalue la stabilité des associations couleur-attribut au sein d'une instance unique. Dans notre cas, la distribution de test étant uniforme, une association stable devrait se manifester par une différence entre les distributions des couleurs, conditionnelle à une certaine catégorie dans un attribut.

Méthode : Comparaison des distributions de couleurs entre toutes les paires de catégories distinctes d'un même attribut binné (ex : 'œuf' vs 'triangle' pour l'attribut forme, ou 'rotation $\pi/8$' vs 'rotation $9\pi/8$' pour l'orientation).

Test statistique : Test de Kolmogorov-Smirnov (KS) pour évaluer les différences significatives entre distributions.

Validation : Le critère est satisfait si toutes les paires de catégories d'un même attribut présentent des distributions significativement différentes ($p < 0.05$) sur le canal Hue et au moins un canal RGB.

Critère d'Arbitraire

Ce critère détermine la spécificité des associations à chaque instance entraînée.

Méthode : Comparaison par paires des distributions de couleurs générées par différentes instances pour une même catégorie d'attribut (ex : distribution des couleurs pour 'triangle' générée par l'Instance A vs Instance B).

Test statistique : Test de KS appliqué entre toutes les paires d'instances.

Validation : Le critère est satisfait si, pour au moins un attribut binné, au moins une instance diffère significativement ($p < 0.05$) d'au moins une autre instance. Par exemple, si l'Instance A associe 'triangle' majoritairement au rouge tandis que l'Instance B l'associe au bleu.

2.3.3 Configurations Expérimentales et Hypothèses

Notre protocole expérimental vise à évaluer l'émergence de la synesthésie artificielle en comparant deux conditions d'entraînement principales du modèle :

- **Modèles Complets :** Ces modèles sont entraînés avec un accès complet et symétrique à l'information de couleur dans les deux modalités (visuelle et attributs). Conformément à nos attentes de pré-enregistrement, nous n'anticipons **pas d'émergence** de synesthésie artificielle dans cette condition, qui sert de contrôle.
- **Modèles avec Vide Sémantique :** Ces modèles sont entraînés sous une condition d'asymétrie informationnelle, où l'information de couleur est délibérément omise de la modalité des attributs. Notre attente principale, issue du pré-enregistrement, est que cette condition **favorisera l'émergence** d'associations couleur-attributs régulières et arbitraires, analogues à la synesthésie.

Nous comparons les Modèles Complets (contrôle) aux Modèles avec Vide Sémantique. Ces derniers derniers sont entrainés selon cinq configurations de pondération des *losses* $(\alpha, \beta, \gamma, \delta)$ chacune avec trois instances (initialisations distinctes) pour évaluer l'arbitraire. Un Modèle Complet par pondération sert de référence.

Nos hypothèses spécifiques, guidées par le pré-enregistrement, et les rationalités exploratoires pour chaque configuration sont les suivantes :

H1 : (Pré-enregistrement) Impact de la *loss* de Cycle-Complet : *Une pondération accrue de la loss de cycle-complet favorisera l'émergence et la force de la synesthésie artificielle.* Cette hypothèse est évaluée en comparant principalement la **Configuration 4 (Emphase Cycle-Complet)** : $(\alpha = 1, \beta = 0.1, \gamma = 1, \delta = 10)$ à la **Configuration 1 (Référence)** : $(\alpha = 1, \beta = 0.1, \gamma = 1, \delta = 1)$.

H2 : (Pré-enregistrement) Importance du Chemin de Traitement : *Les signes d'émergence de la synesthésie artificielle seront plus marqués lorsqu'évalués sur le chemin de reconstruction Cycle-Complet que sur les chemins plus directs (Demi-Cycle, Traduction), en raison de la nécessité accrue de recourir à l'information de couleur encodée implicitement.* Cette hypothèse sera testée en analysant les scores d'émergence via ces différents chemins pour une même configuration.

Les cinq configurations de pondération testées sont (incluant celles liées à H1) :

- **Configuration 1 (Référence) :** $(\alpha = 1, \beta = 0.1, \gamma = 1, \delta = 1)$. Sert de baseline pour évaluer l'effet de l'asymétrie informationnelle avec des pondérations d'objectifs équilibrées.
- **Configuration 2 (Emphase Traduction) :** $(\alpha = 10, \beta = 0.1, \gamma = 1, \delta = 1)$. *Rationalité exploratoire :* Évaluer si une forte contrainte sur la traduction inter-modale directe (Attributs $\rightarrow$ Vision) module la formation d'associations.
- **Configuration 3 (Emphase Contrastive) :** $(\alpha = 1, \beta = 1, \gamma = 1, \delta = 1)$. *Rationalité exploratoire :* Examiner si un alignement global plus strict des représentations dans le GW influence l'émergence d'associations, l'information excédentaire sera t'elle forcée dans la représentation de celle commune ? Ou au contraire cela conduira t'il a un lissage mettant de côté l'information supplémentaire ?
- **Configuration 4 (Emphase Cycle-Complet) :** $(\alpha = 1, \beta = 0.1, \gamma = 1, \delta = 10)$. Directement liée à **H1**, cette configuration vise à maximiser la pression pour l'encodage implicite de la couleur.
- **Configuration 5 (Emphase Attributs Continus) :** $(\alpha = 1, \beta = 0.1, \gamma = 1, \delta = 1)$, avec un poids relatif x5 pour les attributs continus (taille, position, orientation) par rapport à l'attribut 'forme' dans le calcul de la $L_{translation}$ (Attributs $\rightarrow$ Vision). *Rationalité exploratoire :* En accentuant la nécessité de reconstruire fidèlement les attributs continus (taille, position, orientation) nous **diminuons l'importance relative de la reconstruction de l'attribut 'forme'**. Notre hypothèse était que la nature catégorielle de la forme, représentée par seulement 3 valeurs distinctes dans un espace infini ($\mathbf{R}^3$) offrirait un espace représentationnel moins dense ou plus "permissif" comparé aux attributs continus. Cette "marge de manœuvre" ou flexibilité représentationnelle pourrait lui permettre d'**encoder implicitement des informations de couleur n'ayant pas d'accroche explicite**, contribuant ainsi à la minimisation de la *loss* de Cycle Complet, en "portant" une partie de l'information couleur qui lui est omise explicitement.

Une attente générale de notre étude portait sur la **propension de l'attribut 'forme' à développer des associations avec la couleur**. En raison de sa nature catégorielle (représentée en one-hot par des points discrets), nous supposions qu'il serait particulièrement apte à servir d'« ancrage » stable pour l'information de couleur implicite. Sa représentation dans un espace continu, potentiellement moins dense, pourrait offrir de la place pour stocker cette information additionnelle.

L'ensemble de ce plan expérimental vise à déterminer comment les contraintes architecturales (asymétrie informationnelle) et d'apprentissage (pondération des *losses*) interagissent pour potentiellement générer des associations inter-modales non triviales, stables, spécifiques et additionnelles, caractéristiques de notre définition de la synesthésie artificielle.

Les sections précédentes ont établi le cadre théorique, défini la problématique et détaillé la méthodologie mise en oeuvre. Nous allons maintenant présenter les résultats obtenus en appliquant cette méthodologie, afin de chercher à répondre à notre question de recherche concernant les conditions d'émergence d'une synesthésie artificielle au sein de notre modèle computationnel. Le chapitre suivant décrira les expériences spécifiques menées et analysera les données collectées selon les critères de régularité, d'arbitraire et d'additionnalité définis ici.

Chapitre 3

Résultats Expérimentaux

Introduction

Ce chapitre présente les résultats expérimentaux obtenus en appliquant la méthodologie détaillée dans le Chapitre 2. L'analyse évalue l'émergence de signes de synesthésie artificielle – caractérisée par la régularité et l'arbitraire des associations couleur-attributs – dans les Modèles avec Vide Sémantique. Nous examinons l'impact des différentes configurations de pondération des *losses* , des chemins de transformation de l'information, ainsi que le respect du critère d'Additionnalité.

3.1 Émergence d'Associations

Cette section examine l'émergence d'associations couleur-attributs présentant les caractéristiques de la synesthésie artificielle dans les Modèles avec Vide Sémantique. Nous analysons successivement la régularité des associations au sein d'une instance, leur spécificité entre instances, puis vérifions que ces phénomènes n'altèrent pas les capacités fondamentales du modèle.

3.1.1 Critère de Régularité

Le critère de régularité vérifie si, pour une instance donnée, les distributions de couleurs reconstruites diffèrent statistiquement entre les catégories d'un même attribut. Il est validé pour une **instance et un attribut** si les distributions associées à *au moins une paire de catégories* diffèrent significativement (Test KS, $p < 0.05$) simultanément sur le canal Hue et au moins un canal RGB. **Aucune distinction de ce type n'a été observée pour les Modèles Complets (contrôles).**

Résultats principaux : L'attribut **Orientation** montre une capacité de distinction particulièrement forte, avec 100% des instances dans plusieurs configurations (Référence, Emphase Cycle-Complet, Emphase Attributs Continus) sur le chemin Traduction. La **Forme** présente également cette capacité (33% des instances) dans plusieurs configurations. Les attributs Taille et Position X y parviennent plus rarement, tandis que Position Y n'a montré aucune régularité. Ces résultats sont synthétisés dans le tableau B.2 pour les Modèles avec Vide Sémantique.

L'application détaillée de notre critère de Régularité est illustrée en annexe (fig. C.2) pour l'attribut Orientation, montrant comment ces distinctions sont identifiées.

3.1.2 Critère d'Arbitraire (Spécificité Inter-Instances)

Pour chaque catégorie d'attribut ayant montré une régularité intra-instance, nous déterminons si sa distribution de couleurs diffère significativement entre au moins une paire d'instances. Cette analyse permet de vérifier que les associations, bien que régulières au sein d'une instance, restent spécifiques à celle-ci.

Le Tableau 3.1 synthétise ces résultats en présentant les "scores d'arbitraire" des associations couleur-attributs dans les Modèles avec Vide Sémantique. Pour chaque condition (configuration, chemin, attribut), le rapport indique : Nombre de catégories présentant une spécificité inter-instances / Nombre total de catégories ayant démontré une régularité intra-instance. Un tiret (-) signale l'absence de régularité préalable.

Un exemple concret de cette spécificité inter-instances est donné en Figure 3.1, comparant les histogrammes de distributions de teintes de couleurs conditionnelles à la forme diamant, entre deux instances d'une même configuration du modèle.

TABLE 3.1 : Scores d'arbitraire des associations de couleur par attribut et condition expérimentale.

Configuration	Chemin	Forme	Taille	Pos X	Pos Y	Orientation
Référence	Cycle Complet	-	-	-	-	-
	Traduction	2/2	-	-	-	5/16
Emphase Traduction	Cycle Complet	-	-	-	-	8/16
	Traduction	-	-	-	-	-
Emphase Contrastive	Cycle Complet	-	-	-	-	-
	Traduction	-	-	-	-	-
Emphase Cycle Complet	Cycle Complet	-	-	-	-	-
	Traduction	2/2	0/3	0/2	-	14/16
Emphase Attributs Continus	Cycle Complet	-	-	-	-	-
	Traduction	1/2	-	-	-	1/15

Les valeurs représentent le rapport $\frac{\text{Nb Catégories Spécifiques}}{\text{Nb Catégories Évaluées}}$. Le **numérateur** représente le nombre de catégories dont la distribution de couleurs varie significativement entre instances. Le **dénominateur** correspond au nombre total de catégories de l'attribut qui ont contribué à établir des distinctions inter-catégories régulières (somme sur les trois instances de chaque configuration). Un tiret (-) indique l'absence de régularité préalable pour cette condition, rendant l'évaluation de la spécificité non applicable.

L'attribut **Orientation** se distingue par une forte spécificité inter-instances dans plusieurs conditions où la régularité était établie : notamment dans la configuration Référence (Traduction, 5/16 catégories spécifiques), Emphase Traduction (Cycle-Complet, 8/16), et Emphase Cycle-Complet (Traduction, 14/16). L'Emphase Attributs Continus (Traduction) montre également une spécificité pour 1/15 des catégories d'orientation.

L'attribut **Forme** manifeste également une spécificité inter-instances notable. Dans les configurations Référence et Emphase Cycle-Complet (chemin Traduction), les deux formes pour lesquelles une régularité avait été détectée montrent aussi une variabilité inter-instances (score 2/2). Pour la configuration Emphase Attributs Continus (chemin Traduction), une des deux formes évaluables (1/2) présente cette spécificité. Il est intéressant de noter que les formes spécifiques impliquées dans cette variabilité inter-instances ne sont pas toujours les mêmes à travers les configurations : par exemple, dans la configuration Emphase Attributs Continus, c'est la distribution de couleurs des triangles qui diffère entre instances, tandis que dans celle Emphase Cycle-Complet, ce sont celles du diamant et de l'oeuf.

En revanche, les attributs **Taille** et **Pos X**, bien qu'ayant montré une régularité intra-instance dans un cas (Emphase Cycle-Complet, Traduction), n'ont pas produit d'associations spécifiques aux instances dans cette condition (scores de 0/3 et 0/2 respectivement). Les liens stables formés par ces attributs étaient donc similaires entre les instances concernées.

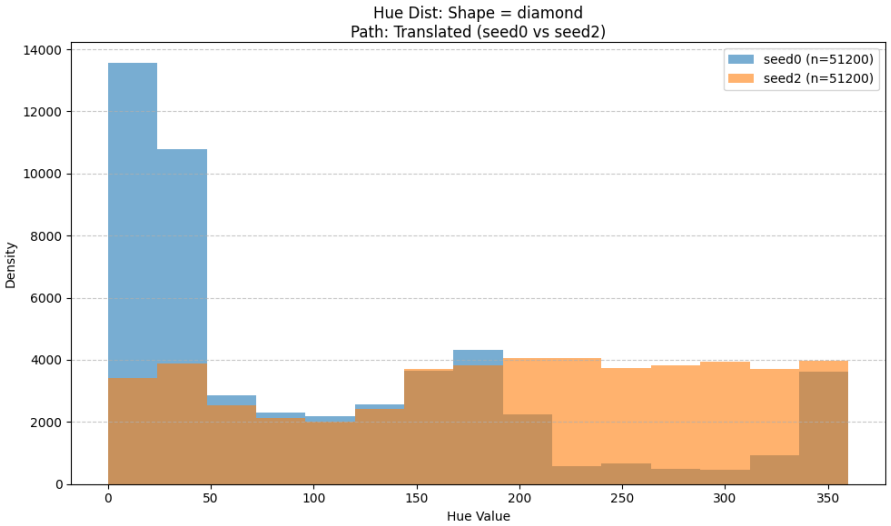


FIGURE 3.1 : Illustration du critère d'arbitraire par la comparaison des distributions de teinte (Hue) pour une catégorie d'attribut fixe, entre deux instances de la configuration de référence. Le graphique montre les histogrammes de densité des valeurs de teinte (allant de 0 à 360) générées pour l'attribut 'Forme = diamant', via le chemin de Traduction. La distribution bleue correspond à l'instance entrainée avec le noyau d'aléatoire (*seed*) 0 du modèle, tandis que la distribution orange correspond à l'instance *seed* 2. On observe une différence notable dans les distributions : *seed* 0 tend à associer la forme diamant à des teintes dans la gamme des rouges-jaunes (valeurs de teinte plus basses, pic principal autour de 20-40), tandis que le *seed* 2 associe la même forme diamant à une gamme de teintes plus larges et différentes, relativement uniformes. Cette divergence visuelle entre les distributions de couleurs générées par des instances de modèle entraînées indépendamment, pour un même inducteur, est un exemple de la spécificité inter-instances (arbitraire) caractéristique de la synesthésie artificielle observée.

3.2 Validation du Critère d'Additionnalité et Examen des Images Générées

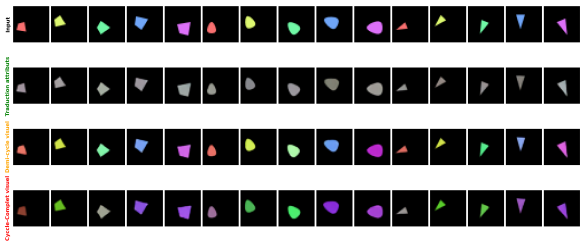
Avant de conclure sur l'émergence d'associations synesthésiques, nous vérifions que ces phénomènes n'altèrent pas les capacités fondamentales des modèles en traitement visuel et catégoriel.

L'évaluation qualitative des reconstructions révèle que **toutes les configurations satisfont la fidélité des attributs non-couleur** (forme, taille, position, orientation) lors des traductions Attributs → Image. Une désaturation des images est observée (cf fig. 3.2) analysée en section D.1 La question de savoir comment la saturation est spécifiquement encodée, au-delà de cette tendance générale, fait l'objet d'une exploration complémentaire en Annexe E.

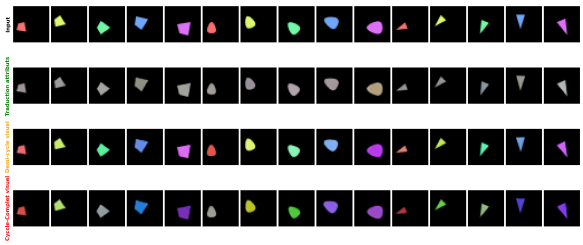
Concernant le **maintien du traitement visuel**, les configurations Référence et Emphase Cycle Complet restituent correctement la couleur dans le traitement intra-modal (Image → Image), tandis que la configuration **Emphase Contrastive présente une dégradation marquée**, constituant une entrave significative à ses capacités de base.

Il est notable que pour la reconstruction en cycle complet, certaines informations de couleur sont préservées malgré le passage par la modalité des attributs, notamment dans les configuration de référence, Emphase Attributs Continus, et particulièrement pour l'Emphase Cycle Complet qui présente une reconstruction de couleur remarquablement fidèle.

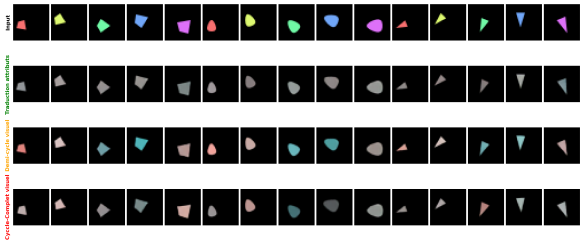
La Figure 3.2 illustre ces différents types de reconstructions pour quelques configurations représentatives, permettant de visualiser les niveaux de fidélité discutés.



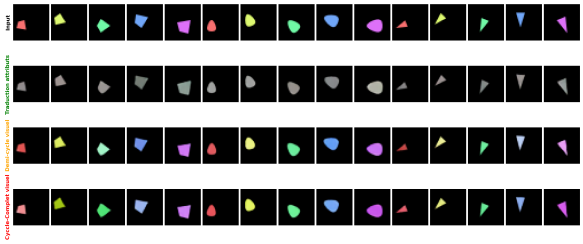
(a) Configuration Référence



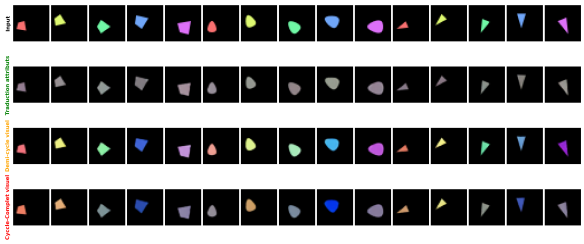
(b) Emphase Attributs Continus



(c) Emphase *loss* Contrastive



(d) Emphase *loss* de Cycle-Complet



(e) Emphase *loss* de Traduction

FIGURE 3.2 : Exemples d'images reconstruites pour différentes configurations d'entraînement du modèle **avec Vide Sémantique**. Chaque sous-figure (a-e) illustre les résultats pour la première instance entraînée d'une configuration spécifique. Pour chaque sous-figure : la première ligne est l'image d'entrée ; la seconde, l'image reconstruite à partir des attributs la décrivant (Attributs → GW → Image) ; la troisième, la reconstruction après un demi-cycle visuel (Image → GW → Image) ; et la quatrième, la reconstruction après un cycle-complet (Image → GW → Attributs → GW → Image). Pour la **reconstruction par traduction** (deuxième ligne de chaque sous-figure), le modèle reçoit en entrée le vecteur d'attributs qui, pour les Modèles avec Vide Sémantique, ne contient **pas l'information de couleur** de l'objet. En revanche, pour la **reconstruction à partir d'une entrée visuelle** (troisième ligne, demi-cycle visuel), le modèle part de l'image d'entrée originale, qui contient l'information de couleur.

3.3 Synthèse de l'Émergence Synesthésique Artificielle

Cette section synthétise l'émergence de synesthésie artificielle dans les Modèles avec Vide Sémantique, basée sur l'évaluation de l'Additionnalité, de la Régularité et de l'Arbitraire. L'émergence significative d'associations couleur-attributs est jugée présente si ces trois critères sont conjointement satisfaits.

Les Modèles Complets, utilisés comme groupes de contrôle, ont tous convergé (cf tab. B) et démontré leurs capacités fonctionnelles d'intégration multimodale sans défaillance. Crucialement, **aucun Modèle Complet n'a montré la moindre capacité à distinguer statistiquement les distributions de couleurs associées aux différentes catégories d'attributs**,

peu importe le chemin emprunté, indiquant l'absence totale de formation d'associations couleur-attributs régulières dans ces modèles.

Pour les Modèles avec Vide Sémantique, le Tableau 3.2 présente une vue consolidée des configurations et attributs pour lesquels les trois critères (Additionnalité, Régularité, Arbitraire) ont été remplis. La première colonne récapitule le statut de l'Additionnalité, évalué en détail en Section 3.2. Les colonnes suivantes indiquent les attributs pour lesquels la Régularité (distinction intra-instance, Tableau B.2) et l'Arbitraire (numérateur > 0 dans Tableau 3.1) ont été conjointement observés, sur les chemins Cycle-Complet et Traduction respectivement.

TABLE 3.2 : Synthèse de l'émergence de synesthésie artificielle (critères d'Additionnalité, Régularité et Arbitraire satisfaits) pour les attributs binnés, par configuration de *losses* (Modèles avec Vide Sémantique), évaluée sur les chemins Cycle-Complet et Traduction.

Configuration	Additionnalité	Attributs avec Régularité & Arbitraire (Cycle-Complet)	Attributs avec Régularité & Arbitraire (Traduction)
Référence	Satisfait	-	Forme, Orientation
Emphase Traduction	Satisfait	Orientation	-
Emphase Cycle-Complet	Satisfait	-	Forme, Orientation
Emphase Contrastive	Non-satisfait		
Emphase Attributs Continus	Satisfait	-	Forme, Orientation

Les résultats synthétisés dans le Tableau 3.2 mettent en évidence les points clés suivants :

- La configuration **Emphase Contrastive** est la seule à ne pas satisfaire l'Additionnalité, ni par ailleurs aucune association
- Les autres configurations (Référence, Emphase Traduction, Emphase Cycle-Complet, Emphase Attributs Continus) ont toutes validé l'Additionnalité.
- L'attribut **Orientation** est le principal candidat à l'émergence (cooccurrence Régularité/Arbitraire) dans plusieurs configurations sur le chemin Traduction et pour Emphase Traduction sur le chemin Cycle-Complet.
- L'attribut **Forme** montre également cette cooccurrence dans les configurations Référence, Emphase Cycle-Complet et Emphase Attributs Continus, spécifiquement sur le chemin Traduction.
- Les attributs **Taille** et **Position X**, bien que parfois réguliers, n'ont pas satisfait l'Arbitraire (scores de 0 dans Tableau 3.1) lorsque la régularité était présente, leurs associations stables n'étant pas instance-spécifiques.
- L'attribut **Position Y** n'a montré aucune émergence (ni Régularité, ni Arbitraire) dans aucune configuration.
- Le chemin Attributs vers Image (Traduction) est le vecteur principal de l'émergence complète pour Forme et Orientation dans la majorité des configurations. Le chemin Cycle-Complet ne montre cette émergence que pour l'Orientation (Emphase Traduction).

En conclusion, nos critères sont satisfaits pour les attributs Forme et Orientation dans les Modèles avec Vide Sémantique, exception faite de la Configuration Emphase Contrastive. Cette émergence est absente dans les Modèles Complets (contrôles), Les variations dans les configurations de *losses* influencent l'émergence selon les attributs et chemins.

Chapitre 4

Discussion

Introduction

Ce chapitre propose une interprétation des résultats expérimentaux détaillés au Chapitre 3. Nous confronterons nos observations aux hypothèses initiales, discuterons des implications théoriques de ces associations émergentes, présenterons les limites de notre étude, en esquissant des perspectives pour de futures recherches. et enfin, mettrons en lumière les contributions de ce travail.

4.1 Analyse des Résultats au Regard des Hypothèses

Notre étude visait à déterminer si un modèle d'apprentissage profond à l'architecture neuro-inspirée pouvait développer des associations intermodales analogues à la synesthésie (c'est-à-dire régulières, arbitraires et additionnelles, cf sec. 1.3.2) Pour cela, nous nous sommes appuyés sur l'hypothèse que la simulation d'un "vide sémantique" – inspirée des théories explicatives de la synesthésie humaine – via l'omission de l'information de couleur dans la modalité des attributs, favoriserait cette émergence dans notre modèle multimodal basé sur la GWT.

L'attente principale, issue de ce cadre théorique, était que la **synesthésie artificielle émergerait exclusivement dans les Modèles avec Vide Sémantique**, où l'information de couleur était omise des attributs, mais pas dans les Modèles Complets (contrôles). Les résultats détaillés en Section 3.3 (Tableau 3.2) **confirment sans ambiguïté cette prédiction** : des associations satisfaisant nos trois critères ont été détectées exclusivement dans les Modèles avec Vide Sémantique, soulignant le rôle fondamental de l'asymétrie informationnelle comme condition nécessaire à ce phénomène dans notre cadre expérimental.

Concernant nos hypothèses spécifiques (sec. 2.3.3) sur les facteurs modulant cette émergence dans les Modèles avec Vide Sémantique :

- **H1 (Impact de la *loss* de Cycle-Complet)** : Cette hypothèse suggérait qu'une pondération accrue de la *loss* de Cycle-Complet $L_{full-cycle}$) intensifierait l'émergence de la synesthésie artificielle. La Configuration 4 (Emphase Cycle-Complet) a été conçue pour tester cela par rapport à la Configuration 1 (Référence). Les résultats (Tableaux B.2 et 3.1) indiquent que la Configuration "Emphase Cycle-Complet" a effectivement produit une émergence notable d'associations Forme-Couleur et Orientation-Couleur via le chemin de Traduction, comparable, voire légèrement plus prononcée pour certaines catégories d'orientation (14 sur 16 montrant de l'arbitraire, contre 5 sur 16 pour la Référence), par rapport à la configuration Référence qui montrait déjà une forte tendance à l'émergence pour ces mêmes attributs et ce chemin. Cela **soutient H1**, car bien que l'asymétrie informationnelle seule (dans la config Référence) soit déjà un puissant inducteur, l'accentuation de la *loss* de Cycle-Complet semble consolider ou étendre ces associations. Le mécanisme proposé est que cette *loss* , en exigeant une reconstruction fidèle après un "aller-retour"

complet de l'information à travers les deux modalités (y compris la modalité "Attributs" qui est "aveugle" à l'information de couleur explicite), impose une contrainte particulièrement forte sur le modèle. Pour minimiser cette erreur de cycle, le système est fortement incité à développer et à fiabiliser des stratégies d'encodage implicite de la couleur, en l'associant de manière stable et distincte aux autres attributs disponibles. La pression pour une cohérence cyclique rend ces associations implicites nécessaires pour une bonne performance sur cet objectif spécifique.Il est crucial de noter que les pondérations sont relatives ; l'accentuation d'autres pertes (Traduction, Contrastive) dans les configurations 2 et 3 a diminué l'importance relative de $L_{full-cycle}$, ce qui corrèle avec une réduction ou absence d'associations observées, renforçant cette interprétation

- **H2 (Importance du Chemin de Traitement)** suggérait que les signes d'émergence seraient plus marqués sur le chemin Cycle-Complet. Nos résultats offrent une image nuancée. Si la configuration Emphase Traduction a montré une émergence pour l'Orientation exclusivement sur le chemin Cycle-Complet, la majorité des autres cas d'émergence (notamment pour Forme et Orientation sous Référence et Emphase Cycle-Complet) se sont manifestés via le chemin Traduction (Attributs → Vision). Cela **ne confirme pas H2 de manière univoque** comme étant le chemin universellement le plus propice. Il semble plutôt que lorsque l'importance relative de la loss de cycle complet n'est pas diminuée, la pression pour générer directement la modalité visuelle à partir des attributs incomplets (**chemin Traduction**) soit un moteur très efficace pour la formation de ces liens, potentiellement complété ou modulé par les contraintes du cycle-complet dans certaines configurations. Il est à noter que les reconstructions issues de ce chemin Traduction tendent à être achromatiques, un phénomène que nous discutons plus en détail en Section D.1 et E.

Quant aux autres configurations exploratoires :

- L'**Emphase Traduction** (Config. 2) favorise principalement l'émergence pour l'Orientation via le chemin Cycle-Complet, révélant des interactions complexes entre objectifs de *losses*. Accentuer la traduction réduit les "risques" que le modèle accepte de prendre en traduction directe, faisant converger les images générées vers une valeur unique minimisant probablement l'erreur au regard de la distribution d'entraînement des couleurs, là où cela favorise leur apparition en cycle complet. Le cycle complet étant deux traductions consécutives, on peut supposer que ce dernier voit émerger des associations synesthétiques via le mécanisme que nous avions initialement proposé,

- L'**Emphase Contrastive** (Config. 3) n'a conduit à **aucune émergence** d'associations régulière, en plus de gommer les couleurs après passage par le GW. Ceci pourrait s'expliquer par la forte propension de cette *loss* à favoriser un encodage **cohérent** entre les modalités, en se concentrant sur les informations **symétriques**. Il semble que le GW issu de cette configuration est "aveugle" à l'information de couleur, l'encodage de la modalité visuelle étant incité à l'ignorer, amenant le modèle à ne **pas l'intégrer dans ses représentations internes**. Il semble donc nécessaire que le modèle puisse faire maintenir une distinction entre les modalités lui permettant de garder une sorte de **signature de la modalité d'origine**, rejoignant empiriquement l'étude théorique de Jiang & al. [42] : un alignement parfait peut inhiber l'émergence de mécanismes adaptatifs sophistiqués.

- L'**Emphase Attributs Continus** (Config. 5) a maintenu une émergence de régularité pour la Forme et l'Orientation, mais a **fortement réduit l'arbitraire** de ces associations. Malgré la moindre contrainte sur la reconstruction de la forme, la forte priorité accordée aux attributs continus a conduit à des associations couleur-attributs plus similaires entre les instances (par exemple, pour la Forme, l'arbitraire est passé de 2/2 à 1/2 et pour l'Orientation de 5/16 à 1/15, comparé à la Référence). Cela pourrait signifier que le modèle converge vers des stratégies d'encodage implicite plus uniformes sous cette contrainte.

Conformément à notre hypothèse selon laquelle la nature catégorielle et fondamentale de l'attribut **Forme** le rendrait propice à l'établissement de liens synesthésiques, celui-ci a effectivement démontré une capacité à développer des associations régulières et arbitraires avec la couleur dans plusieurs configurations. La variabilité des formes spécifiques (par exemple, triangles ou diamants/oeufs) manifestant des associations arbitraires selon les conditions d'entraînement (voir Section 3.1.2) souligne bien le caractère idiosyncrasique de ces liens, modulé par les particularités de chaque processus d'apprentissage.

De manière plus notable, et dépassant nos prévisions initiales qui se concentraient davantage sur la forme, l'attribut **Orientation** s'est avéré être le plus systématiquement impliqué dans l'émergence d'associations synesthésiques artificielles. Une explication plausible de cette prévalence pourrait résider dans une **correspondance topologique** potentielle : la nature intrinsèquement cyclique de l'orientation (variant de 0 à 2π radians) pourrait s'aligner de manière particulièrement efficace avec la dimension Teinte (Hue) de l'espace colorimétrique HSL, illustré en Figure C.1., qui est également cyclique. Cette congruence structurelle, couplée à l'importance de l'orientation pour la structuration de l'information visuelle, pourrait expliquer pourquoi la rotation est ici un "point d'ancrage" privilégié pour l'encodage implicite de l'information de couleur.

Ces observations suggèrent que si la saillance conceptuelle (comme pour la Forme) est un facteur, des correspondances structurelles ou topologiques entre les domaines de l'inducteur et du concurrent (comme pour l'Orientation et la Teinte) pourraient jouer un rôle encore plus déterminant dans la facilité avec laquelle de telles associations intermodales émergent dans un système artificiel. Par ailleurs, une interaction entre ces facteurs semble probable et nécessiterais d'être explorée. Par exemple : le modèle pourrait associer du rouge au triangle orienté de trois-quarts, plutôt qu'aux triangles en général, ou aux formes orientées de trois quarts en général, révélant des associations compositionnelles complexes.

4.2 Implications Théoriques

Ces résultats expérimentaux, bien que circonscrits à un modèle et un jeu de données spécifiques, ouvrent plusieurs pistes de réflexion théorique :

- **Analogies Computationnelles avec les Théories de la Synesthésie Humaine :**
  - Nos résultats fournissent un **support computationnel tangible** à l'hypothèse selon laquelle un "vide sémantique" (ici, l'absence de l'attribut couleur explicite) peut induire la formation d'associations stables pour structurer l'information. En effet, en concevant la modalité 'attributs' comme le lieu de la catégorisation abstraite et la modalité 'visuelle' comme celui de la perception sensorielle, l'omission de l'information de couleur des attributs a créé ce 'vide'. Le fait que le modèle "ancre" la couleur à des attributs pour combler cette lacune informationnelle simule un mécanisme plausible de la synesthésie sous sa conceptualisation d'idéesthésie.
  - *Apprentissage et Spécificité :* La nature arbitraire (spécifique à l'instance) des associations rappelle le rôle de l'apprentissage et des trajectoires développementales uniques dans la formation des paires synesthésiques humaines. L'initialisation aléatoire et l'optimisation stochastique de nos modèles créent des "histoires d'apprentissage" distinctes, menant à des "signatures" synesthésiques individuelles.
- **Implications pour l'IA Multimodale :** Le concept de vide sémantique exploré ici fait écho en IA multimodale à la notion plus large de "gap informationnel" (cf. Section 1.2.1), situation générale dans laquelle les informations issues de différentes modalités ne se recouvrent pas. Nos résultats suggèrent que ces asymétries, loin de constituer de simples obstacles, peuvent au contraire agir comme des catalyseurs d'innovation représentationnelle. Elles favorisent l'émergence de propriétés nouvelles, potentiellement bénéfiques sur le

plan fonctionnel. Plus spécifiquement, cette étude indique que les modèles d'IA, confrontés à de telles asymétries, sont capables de développer des associations intermodales plus subtiles et idiosyncratiques que la simple capture de corrélations statistiques explicites. Cette capacité ouvre des perspectives pour la conception de systèmes plus robustes et adaptatifs, notamment pour gérer l'ambiguïté, combler des informations manquantes de manière créative, ou encore développer des formes de 'biais' personnalisés, façonnés par leur 'expérience' d'apprentissage unique.

4.3 Limites et Perspectives Futures

Notre démarche exploratoire a permis d'établir les bases d'une synesthésie artificielle, mais révèle plusieurs limites méthodologiques et architecturales qui constituent autant d'axes de développement futurs. Les **contraintes temporelles** rencontrées, notamment suite à la correction tardive d'une incohérence dans la gestion des attributs non normalisés lors du Cycle-Complet, ont **limité l'exploration hyperparamétrique** et appellent à des investigations plus approfondies.

4.3.1 Limitations Principales

L'approche adoptée dans cette étude, bien que fructueuse pour démontrer l'émergence de phénomènes synesthésiques artificiels, présente un certain nombre de limitations qui en restreignent la portée et la profondeur d'analyse :

Absence de traitement abstrait de la couleur. Notre architecture présente une limitation fondamentale : l'absence d'un module dédié au traitement de la couleur comme concept abstrait, distinct de sa perception pixelique directe. Les Modèles avec Vide Sémantique traitent actuellement la couleur uniquement comme caractéristique de la modalité visuelle, alors que la synesthésie humaine implique une dualité entre perception "objective" et expérience synesthésique. Un synesthète peut reconnaître qu'un objet est "objectivement bleu" tout en "ressentant du jaune" pour d'autres raisons associatives. Cette dualité échappe à notre architecture actuelle. Notre additionnalité reste donc fonctionnelle mais serait plus pertinente avec un modèle doté d'une capacité de conceptualisation des couleurs.

Simplification expérimentale. L'utilisation du Simple Shapes Dataset (SSD) constitue une réduction importante de la complexité perceptive réelle, limitant la portée de nos conclusions sur les mécanismes synesthésiques.

Évaluation qualitative. L'évaluation de l'Additionnalité reste principalement qualitative, ne permettant pas une mesure précise de l'intensité ou de la stabilité des associations émergentes.

Spécificité architecturale. Les associations observées sont intrinsèquement liées à notre architecture inspirée du GW, questionnant leur généralité.

Simplicité cognitive. Notre modèle actuel manque de mécanismes cognitifs avancés (attention dynamique, apprentissage continu), limitant la richesse des processus modélisés.

4.3.2 Perspectives de Développement Architectural

Concernant l'architecture du modèle, plusieurs évolutions pourraient être envisagées :

- **Architecture trimodale.** Idéalement, nous aurions implémenté une architecture trimodale incluant une modalité dédiée à la couleur abstraite (vecteurs de catégories ou coordonnées HSL), aux côtés des modalités visuelle et catégorielle. Cette approche aurait permis d'étudier l'intégration entre couleur "réelle" (attribut explicite) et couleur "synesthésique" (associations émergentes).

Une alternative consisterait à doter le modèle d'un mécanisme d'attention minimisant l'importance de l'information couleur dans les attributs. Cela reproduirait plus fidèlement la théorie du vide sémantique, où la couleur en tant qu'abstraction n'est pas absente mais pas apprise simultanément. Un bon point de départ pour cela serait d'essayer d'adapter la présente étude au modèle LXMERT [81].

- **Diversité architecturale.** Comparer avec d'autres architectures d'IA multimodale (Transformers, autres architectures inspirées de la GWT) pour élucider la spécificité de nos observations. Approfondir l'analyse des représentations internes pour élucider les mécanismes neuronaux précis de l'encodage implicite au sein du GW.

4.3.3 Perspectives Méthodologiques et Expérimentales

Au-delà des aspects architecturaux, l'approche méthodologique et le cadre expérimental pourraient également bénéficier de développements futurs :

- **Validation quantitative.** Développer des métriques quantitatives pour l'Additionnalité (ex : SSIM [85])
- **Exploration des interactions compositionnelles** : Analyser systématiquement l'impact des combinaisons d'attributs (par exemple forme + orientation) sur les associations couleur émergentes.
- **Utiliser un autre espace d'analyse de couleurs** L'utilisation d'espaces chromatiques perceptuels (CIE L*a*b*, pertinent pour la synesthésie humaine [69]) affinerait l'analyse des couleurs.
- **Généralisation écologique.** Évaluer la généralisabilité de ces phénomènes en testant l'approche sur des jeux de données plus écologiques (images naturelles, sons, texte) et avec d'autres paires de modalités, idéalement sur des espaces représentationnels plus complexes que celui des attributs. Envisager de reproduire d'autres formes de synesthésie.
- **Impact fonctionnel.** Évaluer si les modèles "synesthètes" artificiels présentent des avantages (robustesse au bruit, créativité) sur des tâches subséquentes, en écho aux recherches sur les bénéfices cognitifs chez certains synesthètes.

4.3.4 Approfondissements Théoriques

Au-delà des améliorations techniques, l'ambition est également d'approfondir le dialogue entre notre modélisation computationnelle et les cadres théoriques existants en sciences cognitives :

- **Mécanismes cognitifs avancés.** Explorer l'effet de dynamiques temporelles ou récurrentes dans le GW (réverbération, avec un parallèle potentiel avec la théorie de la résonance stochastique) ou de mécanismes d'apprentissage plus flexibles (plasticité, gating). Étudier le rôle du "nommage" ou du langage dans l'évolution de ces représentations.
- **Intégration aux modèles fonctionnels de la synesthésie.** Approfondir la modélisation de théories d'inspiration neurobiologique, telle que la théorie de l'activation croisée, ou celle de la résonance stochastique. Simuler les mécanismes d'inhibition/désinhibition entre le GW et les attributs pour reproduire l'activation croisée. Explorer le fait de faire plus d'allers-retours entre modalités et GW, ou l'introduction de bruit dans le système pour induire des associations.

4.4 Synthèse finale

Ce mémoire visait à déterminer *dans quelle mesure et sous quelles conditions un modèle d'apprentissage profond inspiré de la GWT peut développer des correspondances satisfaisant à la définition de synesthésie artificielle.*

Notre modèle computationnel peut développer des associations intermodales présentant les signatures synesthésiques (régularité, arbitraire, additionnalité) entre les attributs Forme/Orientation et la couleur, sans altérer ses capacités fondamentales.

L'introduction d'une asymétrie entre perception sensorielle et information "abstraite" a poussé le modèle à ancrer de l'information dans d'autres attributs, modélisant correctement la théorie du vide sémantique. Les différentes configurations, reflétant les priorités d'apprentissage du modèle, révèlent des mécanismes contrastés. D'une part, une priorisation excessive de l'alignement de l'information tend à gommer l'asymétrie lors de la représentation interne des données. Cela suggère qu'il est crucial de préserver une signature modale et une certaine flexibilité pour permettre l'ancrage de l'information – une observation que l'on pourrait résumer par "trop d'ordre tue la créativité". D'autre part, l'accent mis sur la capacité du modèle à traduire l'information de manière cohérente (Cycle complet et Traduction) favorise une gestion efficace de l'asymétrie informationnelle par l'établissement d'associations régulières entre attributs abstraits et couleur.

La nature intrinsèque des attributs s'est révélée déterminante pour l'émergence synesthésique, révélant une hiérarchie inattendue dans les capacités d'induction. L'attribut Forme, initialement pressenti comme candidat optimal en raison de son caractère discret, a effectivement démontré une aptitude significative à l'ancrage des couleurs. Toutefois, la configuration 'Emphase Attributs Continus', conçue pour maximiser la flexibilité représentationnelle, a paradoxalement affaibli l'arbitraire des associations. Plus remarquablement, l'Orientation s'est imposée comme l'inducteur le plus robuste et systématique, dépassant nos prévisions initiales. Cette prévalence pourrait s'expliquer par une correspondance topologique entre la nature cyclique de l'orientation (0-2π) et celle de la dimension Teinte de l'espace HSL.

En conclusion, nos travaux illustrent que des propriétés analogues à la synesthésie artificielle peuvent émerger dans un modèle d'apprentissage profond, un contexte d'asymétrie informationnelle, et sous certaines conditions de configuration appropriée des objectifs d'apprentissage. Ces résultats confirment nos hypothèses principales et offrent un support computationnel à la théorie du vide sémantique. Si des limites subsistent, notamment concernant la complexité des données ou l'évaluation de l'additionnalité, ces travaux ouvrent des perspectives pour des recherches futures sur les mécanismes cognitifs avancés dans les systèmes d'IA, et la manière dont ils pourraient développer des formes d'intégration multimodale plus sophistiquées et personnalisées.

Bibliographie

[1] J.-B. Alayrac et al., *Flamingo : a Visual Language Model for Few-Shot Learning*, 2022. arXiv : 2204.14198 [cs.CV]. adresse : https://arxiv.org/abs/2204.14198.

[2] S. Anash et A. Boileau, "Grapheme-Color Synesthesia and Its Connection to Memory", *Cureus*, t. 16, n° 8, e67524, août 2024, issn : 2168-8184. doi : 10.7759/cureus.67524.

[3] J. E. Asher et al., "A Whole-Genome Scan and Fine-Mapping Linkage Study of Auditory-Visual Synesthesia Reveals Evidence of Linkage to Chromosomes 2q24, 5q33, 6p12, and 12p12", *The American Journal of Human Genetics*, t. 84, n° 2, p. 279-285, 2009, issn : 0002-9297. doi : https://doi.org/10.1016/j.ajhg.2009.01.012.

[4] B. J. Baars, "In the theater of consciousness : The workspace of the mind", *Journal of consciousness studies*, t. 4, n° 4, p. 292-309, 1997.

[5] D. Bahdanau, K. Cho et Y. Bengio, *Neural Machine Translation by Jointly Learning to Align and Translate*, 2016. arXiv : 1409.0473 [cs.CL]. adresse : https://arxiv.org/abs/1409.0473.

[6] T. Baltrušaitis, C. Ahuja et L.-P. Morency, "Multimodal Machine Learning : A Survey and Taxonomy", *IEEE Transactions on Pattern Analysis and Machine Intelligence*, t. 41, n° 2, p. 423-443, 2019. doi : 10.1109/TPAMI.2018.2798607.

[7] K. R. Bankieris et R. N. Aslin, "Implicit associative learning in synesthetes and nonsynesthetes", *Psychonomic Bulletin & Review*, t. 24, n° 3, p. 935-943, 2017. doi : 10.3758/s13423-016-1162-y.

[8] S. Baron-Cohen, M. A. Wyke et C. Binnie, "Hearing Words and Seeing Colours : An Experimental Investigation of a Case of Synaesthesia", *Perception*, t. 16, n° 6, p. 761-767, 1987, PMID : 3454433. doi : 10.1068/p160761. eprint : https://doi.org/10.1068/p160761.

[9] L. W. Barsalou, "Grounded Cognition", *Annual Review of Psychology*, t. 59, n° Volume 59, 2008, p. 617-645, 2008, issn : 1545-2085. doi : https://doi.org/10.1146/annurev.psych.59.103006.093639.

[10] G. Beeli, M. Esslen et L. Jäncke, "Time Course of Neural Activity Correlated with Colored-Hearing Synesthesia", *Cerebral Cortex*, t. 18, n° 2, p. 379-385, juin 2007, issn : 1047-3211. doi : 10.1093/cercor/bhm072. eprint : https://academic.oup.com/cercor/article-pdf/18/2/379/965677/bhm072.pdf.

[11] A. Blum et T. Mitchell, "Combining labeled and unlabeled data with co-training", in *Proceedings of the Eleventh Annual Conference on Computational Learning Theory*, sér. COLT' 98, Madison, Wisconsin, USA : Association for Computing Machinery, 1998, p. 92-100, isbn : 1581130570. doi : 10.1145/279943.279962.

[12] J. R. Bock, "A Deep Learning Model of Perception in Color-Letter Synesthesia", *Big Data and Cognitive Computing*, t. 2, n° 1, 2018, issn : 2504-2289. doi : 10.3390/bdcc2010008.

[13] D. Bor, N. Rothen, D. Schwartzman et al., "Adults Can Be Trained to Acquire Synesthetic Experiences", *Scientific Reports*, t. 4, p. 7089, 2014. doi : 10.1038/srep07089.

[14] D. Brang, E. Hubbard, S. Coulson, M. Huang et V. Ramachandran, "Magnetoencephalography reveals early activation of V4 in grapheme-color synesthesia", *NeuroImage*, t. 53, n° 1, p. 268-274, 2010, issn : 1053-8119. doi : https://doi.org/10.1016/j.neuroimage.2010.06.008.

[15] D. Brang et V. S. Ramachandran, "Survival of the Synesthesia Gene : Why Do People Hear Colors and Taste Words ?", *PLOS Biology*, t. 9, n° 11, p. 1-6, nov. 2011. doi : 10.1371/journal.pbio.1001205.

[16] P. Brugger, D. Knoch, C. Mohr et L. Gianotti, "Is digit-color synaesthesia strictly unidirectional ? Preliminary evidence for an implicitly colored number space in three synaesthetes", *Acta Neuropsychologica*, t. 2, p. 252-258, jan. 2004.

[17] E. Bruni, G. Boleda, M. Baroni et N.-K. Tran, "Distributional semantics in technicolor", in *Proceedings of the 50th Annual Meeting of the Association for Computational Linguistics (Volume 1 : Long Papers)*, 2012, p. 136-145.

[18] E. A. Caspar et R. Kolinsky, "Revue d'un phénomène étrange : la synesthésie", *L'Année psychologique*, t. 113, n° 4, p. 629-666, 2013. doi : 10.3917/anpsy.134.0629.

[19] H. Chateau-Laurent et R. VanRullen, *Learning to Chain Operations by Routing Information Through a Global Workspace*, 2025. arXiv : 2503.01906 [cs.LG]. adresse : https://arxiv.org/abs/2503.01906.

[20] R. E. Cytowic et D. M. Eagleman, *Wednesday Is Indigo Blue : Discovering the Brain of Synesthesia*. Cambridge, MA : MIT Press, 2009, isbn : 9780262012799.

[21] R. E. Cytowic, *Synesthesia : A Union of the Senses*. The MIT Press, mai 2002, isbn : 9780262271073. doi : 10.7551/mitpress/6590.001.0001.

[22] S. Day. "Daysyn Website". (2025), adresse : http://www.daysyn.com/Types-of-Syn.html (visité le 2025).

[23] S. Dehaene et J.-P. Changeux, "The neural correlates of consciousness : a cognitive neuroscience perspective", *Nature reviews neuroscience*, t. 12, n° 4, p. 201-227, 2011.

[24] B. Devillers, L. Maytié et R. VanRullen, *Semi-supervised Multimodal Representation Learning through a Global Workspace*, 2024. arXiv : 2306.15711 [cs.AI]. adresse : https://arxiv.org/abs/2306.15711.

[25] M. J. Dixon, D. Smilek et P. M. Merikle, "Not all synaesthetes are created equal : projector versus associator synaesthetes", *Cognitive, Affective, & Behavioral Neuroscience*, t. 4, n° 3, p. 335-343, 2004. doi : 10.3758/CABN.4.3.335.

[26] M. J. Dixon, D. Smilek, P. L. Duffy, M. P. Zanna et P. M. Merikle, "The Role of Meaning in Grapheme-Colour Synaesthesia", *Cortex*, t. 42, n° 2, p. 243-252, 2006, issn : 0010-9452. doi : https://doi.org/10.1016/S0010-9452(08)70349-6.

[27] D. M. Eagleman, A. D. Kagan, S. S. Nelson, D. Sagaram et A. K. Sarma, "A standardized test battery for the study of synesthesia", *Journal of Neuroscience Methods*, t. 159, n° 1, p. 139-145, 2007. doi : 10.1016/j.jneumeth.2006.07.012.

[28] D. M. Eagleman, "Synaesthesia", *BMJ*, t. 340, 2010, issn : 0959-8138. doi : 10.1136/bmj.b4616. eprint : https://www.bmj.com/content.

[29] N. Eckardt, C. Sinke, S. Bleich, R. Lichtinghagen et M. Zedler, "Investigation of the relationship between neuroplasticity and grapheme-color synesthesia", *Frontiers in Neuroscience*, t. Volume 18 - 2024, 2024, issn : 1662-453X. doi : 10.3389/fnins.2024.1434309.

[30] G. M. Edelman, *The remembered present : A biological theory of consciousness*. (The remembered present : A biological theory of consciousness.). New York, NY, US : Basic Books, 1989, p. xx, 346-xx, 346, isbn : 0-465-06910-X (Hardcover).

[31] A. Frome et al., "DeViSE : A Deep Visual-Semantic Embedding Model", in *Advances in Neural Information Processing Systems*, C. Burges, L. Bottou, M. Welling, Z. Ghahramani et K. Weinberger, éd., t. 26, Curran Associates, Inc., 2013. adresse : https://proceedings.neurips.cc/paper_files/paper/2013/file/7cce53cf90577442771720a370c3c723-Paper.pdf.

[32] A. Goyal et al., *Coordination Among Neural Modules Through a Shared Global Workspace*, 2022. arXiv : 2103.01197 [cs.LG]. adresse : https://arxiv.org/abs/2103.01197.

[33] P. G. Grossenbacher et C. T. Lovelace, "Mechanisms of synesthesia : Cognitive and physiological constraints", *Trends in Cognitive Sciences*, t. 5, n° 1, p. 36-41, jan. 2001. doi : 10.1016/s1364-6613(00)01571-0.

[34] J. Hänggi, D. Wotruba et L. Jäncke, "Globally Altered Structural Brain Network Topology in Grapheme-Color Synesthesia", *Journal of Neuroscience*, t. 31, n° 15, p. 5816-5828, 2011, issn : 0270-6474. doi : 10.1523/JNEUROSCI.0964-10.2011. eprint : https://www.jneurosci.org/content/31/15/5816.full.pdf.

[35] K. He, X. Zhang, S. Ren et J. Sun, *Delving Deep into Rectifiers : Surpassing Human-Level Performance on ImageNet Classification*, 2015. arXiv : 1502.01852 [cs.CV]. adresse : https://arxiv.org/abs/1502.01852.

[36] J. Hoffman, S. Gupta et T. Darrell, "Learning with Side Information through Modality Hallucination", in *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, p. 826-834. doi : 10.1109/CVPR.2016.96.

[37] J. Hong, K. H. Park et T. P. Pavlic, *Concept-Centric Transformers : Enhancing Model Interpretability through Object-Centric Concept Learning within a Shared Global Workspace*, 2023. arXiv : 2305.15775 [cs.LG]. adresse : https://arxiv.org/abs/2305.15775.

[38] E. M. Hubbard et V. S. Ramachandran, "The neurophysiology of synesthesia", *Neuron*, t. 70, n° 5, p. 981-984, 2011.

[39] E. M. Hubbard et V. S. Ramachandran, "Neurocognitive Mechanisms of Synesthesia", *Neuron*, t. 48, n° 3, p. 509-520, nov. 2005, issn : 0896-6273. doi : 10.1016/j.neuron.2005.10.012.

[40] J.-M. Hupé et M. Dojat, "A critical review of the neuroimaging literature on synesthesia", *Frontiers in Human Neuroscience*, t. Volume 9 - 2015, 2015, issn : 1662-5161. doi : 10.3389/fnhum.2015.00103.

[41] Hupé, Jean-Michel, "Synesthésie, expression subjective d'un palimpseste neuronal ?", *Med Sci (Paris)*, t. 28, n° 8, p. 765-771, 2012. doi : 10.1051/medsci/2012288019.

[42] Q. Jiang et al., *Understanding and Constructing Latent Modality Structures in Multi-modal Representation Learning*, 2023. arXiv : 2303.05952 [cs.LG]. adresse : https://arxiv.org/abs/2303.05952.

[43] P. Lalwani et D. Brang, "Stochastic resonance model of synaesthesia", *Philosophical Transactions of the Royal Society B : Biological Sciences*, t. 374, n° 1787, p. 20 190 029, 2019. doi : 10.1098/rstb.2019.0029. eprint : https://royalsocietypublishing.org/doi/pdf/10.1098/rstb.2019.0029.

[44] T. M. van Leeuwen, K. M. Petersson et P. Hagoort, "Synaesthetic Colour in the Brain : Beyond Colour Areas. A Functional Magnetic Resonance Imaging Study of Synaesthetes and Matched Controls", *PLOS ONE*, t. 5, n° 8, p. 1-12, août 2010. doi : 10.1371/journal.pone.0012074.

[45] G. Leschziner, *The man who tasted words : A neurologist explores the strange and startling world of our senses*. St. Martin's Press, 2022.

[46] S. Li et H. Tang, *Multimodal Alignment and Fusion : A Survey*, 2024. arXiv : 2411.17040 [cs.CV]. adresse : https://arxiv.org/abs/2411.17040.

[47] I. Loshchilov et F. Hutter, *Decoupled Weight Decay Regularization*, 2019. arXiv : 1711.05101 [cs.LG]. adresse : https://arxiv.org/abs/1711.05101.

[48] J. Lu, D. Batra, D. Parikh et S. Lee, *ViLBERT : Pretraining Task-Agnostic Visiolinguistic Representations for Vision-and-Language Tasks*, 2019. arXiv : 1908.02265 [cs.CV]. adresse : https://arxiv.org/abs/1908.02265.

[49] J. Lupiañez et A. Callejas, "Automatic perception and synesthesia : Evidence from colour and photism naming in a stroop-negative priming task", *Cortex*, t. 41, n° 2, p. 173-183, 2005. doi : 10.1016/S0010-9452(08)70216-4.

[50] L. Maytié, R. B. Johannet et R. VanRullen, *Multimodal Dreaming : A Global Workspace Approach to World Model-Based Reinforcement Learning*, 2025. arXiv : 2502.21142 [cs.AI]. adresse : https://arxiv.org/abs/2502.21142.

[51] C. B. Mills, M. L. Viguers, S. K. Edelson, A. T. Thomas, S. L. Simon-Dack et J. A. Innis, "The Color of Two Alphabets for a Multilingual Synesthete", *Perception*, t. 31, n° 11, p. 1371-1394, 2002, PMID : 12489772. doi : 10.1068/p3429. eprint : https://doi.org/10.1068/p3429.

[52] A. Mroczko-Wąsowicz et D. Nikolić, "Semantic mechanisms may be responsible for developing synesthesia", *Frontiers in Human Neuroscience*, t. 8, 2014, issn : 1662-5161. doi : 10.3389/fnhum.2014.00509.

[53] R. Murray, "A review of Synesthesia : historical and current perspectives", *UWL Journal of Undergraduate Research XXIV*, 2021.

[54] K. M. Myles, M. J. Dixon, D. Smilek et P. M. Merikle, "Seeing double : The role of meaning in alphanumeric-colour synaesthesia", *Brain and Cognition*, t. 53, n° 2, p. 342-345, nov. 2003. doi : 10.1016/s0278-2626(03)00139-8.

[55] V. Nabokov, *Speak, Memory*. G.P. Putnam's sons, 1966. adresse : https://books.google.fr/books?id=wYrbxgEACAAJ.

[56] J. Neufeld et al., "Disinhibited feedback as a cause of synesthesia : evidence from a functional connectivity study on auditory-visual synesthetes", *Neuropsychologia*, t. 50, n° 7, p. 1471-1477, juin 2012, Epub 2012 Mar 6. doi : 10.1016/j.neuropsychologia.2012.02.032.

[57] J. Ngiam, A. Khosla, M. Kim, J. Nam, H. Lee et A. Ng, "Multimodal Deep Learning", in *International Conference on Machine Learning*, 2011. adresse : https://api.semanticscholar.org/CorpusID:352650.

[58] D. Nikolić, "Is synaesthesia actually ideaesthesia ? An inquiry into the nature of the phenomenon", in *Proceedings of the Third International Congress on Synaesthesia, Science & Art*, Granada, Spain, 26-29 avr. 2009.

[59] D. Nikolić, U. M. Jürgens, N. Rothen, B. Meier et A. Mroczko, "Swimming-style synesthesia", *Cortex*, t. 47, n° 7, p. 874-879, 2011.

[60] "Page Wikipédia "Synesthésie"". French, Wikipédia. (), adresse : https://fr.wikipedia.org/wiki/Synesth%C3%A9sie (visité le 09/05/2025).

[61] M. Palatucci, D. Pomerleau, G. E. Hinton et T. M. Mitchell, "Zero-shot Learning with Semantic Output Codes", in *Advances in Neural Information Processing Systems*, Y. Bengio, D. Schuurmans, J. Lafferty, C. Williams et A. Culotta, éd., t. 22, Curran Associates, Inc., 2009. adresse : https://proceedings.neurips.cc/paper_files/paper/2009/file/1543843a4723ed2ab08e18053ae6dc5b-Paper.pdf.

[62] C. Racey et al., "An Open Science MRI Database of over 100 Synaesthetic Brains and Accompanying Deep Phenotypic Information", *Scientific Data*, t. 10, n° 1, p. 766, nov. 2023, issn : 2052-4463. doi : 10.1038/s41597-023-02664-4.

[63] A. Radford et al., "Learning Transferable Visual Models From Natural Language Supervision", *CoRR*, t. abs/2103.00020, 2021. arXiv : 2103.00020. adresse : https://arxiv.org/abs/2103.00020.

[64] V. S. Ramachandran et E. M. Hubbard, "Synaesthesia - A Window Into Perception, Thought and Language", *Journal of Consciousness Studies*, t. 8, n° 12, p. 3-34, 2001.

[65] V. S. Ramachandran et E. M. Hubbard, "Hearing Colors, Tasting Shapes", *Scientific American*, t. 288, n° 5, p. 52-59, avr. 2003, Full publication date : MAY 2003. adresse : http://www.jstor.org/stable/26060283.

[66] A. Rich, J. Bradshaw et J. Mattingley, "A systematic, large-scale study of synaesthesia : implications for the role of early experience in lexical-colour associations", *Cognition*, t. 98, n° 1, p. 53-84, 2005, issn : 0010-0277. doi : https://doi.org/10.1016/j.cognition.2004.11.003.

[67] M. del Rio, E. Kafadar, V. Fisher, R. D'Costa, A. Powers et J. Ward, "The mechanisms underlying conditioning of phantom percepts differ between those with hallucinations and synesthesia", *Scientific Reports*, t. 14, n° 1, p. 5607, avr. 2024, issn : 2045-2322. doi : 10.1038/s41598-024-53663-3.

[68] N. Root et al., "How "diagnostic" criteria interact to shape synesthetic behavior : The role of self-report and test–retest consistency in synesthesia research", *Consciousness and Cognition*, t. 129, p. 103 819, 2025, issn : 1053-8100. doi : https://doi.org/10.1016/j.concog.2025.103819.

[69] N. Rothen, E. Tsakanikos, B. Meier et J. Ward, "Coloured Letters and Numbers (CLaN) : A reliable factor-analysis based synaesthesia questionnaire", *Consciousness and Cognition*, t. 22, n° 3, p. 1047-1060, 2013, issn : 1053-8100. doi : https://doi.org/10.1016/j.concog.2013.07.005.

[70] N. Rothen, A.-L. Wantz et B. Meier, "Training Synaesthesia", *Perception*, t. 40, n° 10, p. 1248-1250, 2011, PMID : 22308895. doi : 10.1068/p6984. eprint : https://doi.org/10.1068/p6984.

[71] R. Rouw et H. S. Scholte, "Increased structural connectivity in grapheme-color synesthesia", *Nature Neuroscience*, t. 10, n° 6, p. 792-797, juin 2007, issn : 1546-1726. doi : 10.1038/nn1906.

[72] R. Rouw, H. S. Scholte et O. Colizoli, "Brain areas involved in synaesthesia : A review", *Journal of Neuropsychology*, t. 5, n° 2, p. 214-242, 2011. doi : https://doi.org/10.1111/j.1748-6653.2011.02006.x. eprint : https://bpspsychub.onlinelibrary.wiley.com/doi/pdf/10.1111/j.1748-6653.2011.02006.x.

[73] J. Simner, "Why are there different types of synesthete ?", *Frontiers in Psychology*, t. 4, p. 558, 2013. doi : 10.3389/fpsyg.2013.00558.

[74] J. Simner et J. Ward, "The taste of words on the tip of the tongue", *Nature*, t. 444, p. 438, 2006.

[75] J. Simner, "Defining synaesthesia", *British Journal of Psychology*, t. 103, n° 1, p. 1-15, 2012. doi : https://doi.org/10.1348/000712610X528305. eprint : https://bpspsychub.onlinelibrary.wiley.com/doi/pdf/10.1348/000712610X528305.

[76] J. Simner et E. Holenstein, "Ordinal Linguistic Personification as a Variant of Synesthesia", *Journal of Cognitive Neuroscience*, t. 19, n° 4, p. 694-703, avr. 2007, issn : 0898-929X. doi : 10.1162/jocn.2007.19.4.694. eprint : https://direct.mit.edu/jocn/article-pdf/19/4/694/1936309/jocn.2007.19.4.694.pdf.

[77] J. Simner et al., "Synaesthesia : The Prevalence of Atypical Cross-Modal Experiences", *Perception*, t. 35, p. 1024-33, fév. 2006. doi : 10.1068/p5469.

[78] D. Smilek, M. J. Dixon, C. Cudahy et P. M. Merikle, "Synaesthetic photisms influence visual perception", *Journal of Cognitive Neuroscience*, t. 13, n° 7, p. 930-936, oct. 2001. doi : 10.1162/089892901753165845.

[79] D. Smilek, K. A. Malcolmson, J. S. A. Carriere, M. Eller, D. Kwan et M. Reynolds, "When "3" is a Jerk and "E" is a King : Personifying Inanimate Objects in Synesthesia", *Journal of Cognitive Neuroscience*, t. 19, n° 6, p. 981-992, juin 2007, issn : 0898-929X. doi : 10.1162/jocn.2007.19.6.981. eprint : https://direct.mit.edu/jocn/article-pdf/19/6/981/1936382/jocn.2007.19.6.981.pdf.

[80] L. N. Smith et N. Topin, *Super-Convergence : Very Fast Training of Neural Networks Using Large Learning Rates*, 2018. arXiv : 1708.07120 [cs.LG]. adresse : https://arxiv.org/abs/1708.07120.

[81] H. Tan et M. Bansal, *LXMERT : Learning Cross-Modality Encoder Representations from Transformers*, 2019. arXiv : 1908.07490 [cs.CL]. adresse : https://arxiv.org/abs/1908.07490.

[82] M. J. Taylor et al., "Genetic and environmental architecture of synaesthesia and its association with the autism spectrum—a twin study", *Proceedings of the Royal Society B : Biological Sciences*, t. 290, n° 2009, p. 20 231 888, 2023. doi : 10.1098/rspb.2023.1888. eprint : https://royalsocietypublishing.org/doi/pdf/10.1098/rspb.2023.1888.

[83] S. N. Tomson et al., "The genetics of colored sequence synesthesia : Suggestive evidence of linkage to 16q and genetic heterogeneity for the condition", *Behavioural Brain Research*, t. 223, n° 1, p. 48-52, 2011, issn : 0166-4328. doi : https://doi.org/10.1016/j.bbr.2011.03.071.

[84] R. VanRullen et R. Kanai, "Deep Learning and the Global Workspace Theory", *Trends in Neurosciences*, t. 44, n° 9, p. 692-704, 2021. doi : 10.1016/j.tins.2021.06.006.

[85] Z. Wang, A. Bovik, H. Sheikh et E. Simoncelli, "Image quality assessment : from error visibility to structural similarity", *IEEE Transactions on Image Processing*, t. 13, n° 4, p. 600-612, 2004. doi : 10.1109/TIP.2003.819861.

[86] J. Ward, R. Li, S. Salih et N. Sagiv, "Varieties of grapheme-colour synaesthesia : A new theory of phenomenological and behavioural differences", *Consciousness and Cognition*, t. 16, n° 4, p. 913-931, 2007, issn : 1053-8100. doi : https://doi.org/10.1016/j.concog.2006.09.012.

[87] J. Ward et J. Simner, "Lexical-gustatory synaesthesia : linguistic and conceptual factors", *Cognition*, t. 89, n° 3, p. 237-261, 2003, issn : 0010-0277. doi : https://doi.org/10.1016/S0010-0277(03)00122-7.

[88] J. Ward et al., "Synesthesia is linked to large and extensive differences in brain structure and function as determined by whole-brain biomarkers derived from the HCP (Human Connectome Project) cortical parcellation approach", *Cerebral Cortex*, t. 34, n° 11, bhae446, nov. 2024, issn : 1460-2199. doi : 10.1093/cercor/bhae446. eprint : https://academic.oup.com/cercor/article-pdf/34/11/bhae446/60686155/bhae446.pdf.

[89] N. Witthoft et J. Winawer, "Synesthetic Colors Determined by Having Colored Refrigerator Magnets in Childhood", *Cortex*, t. 42, n° 2, p. 175-183, 2006, issn : 0010-9452. doi : https://doi.org/10.1016/S0010-9452(08)70342-3.

[90] N. Witthoft et J. Winawer, "Learning, Memory, and Synesthesia", *Psychological Science*, t. 24, n° 3, p. 258-265, 2013, PMID : 23307940. doi : 10.1177/0956797612452573. eprint : https://doi.org/10.1177/0956797612452573.

Appendices

Annexe A

Citation de Vladimir Nabokov

> Peut-être que "entendre" n'est pas tout à fait exact, car la sensation de couleur semble être produite par l'acte même de former oralement une lettre donnée tout en imaginant son contour. Le "a" long de l'alphabet anglais (et c'est cet alphabet que j'ai à l'esprit par la suite, sauf indication contraire) a pour moi la teinte du bois patiné, mais un "a" français évoque l'ébène poli. Ce groupe noir comprend également le "g" dur (caoutchouc vulcanisé) et le "r" (un chiffon plein de suie en train d'être déchiré). Le "n" couleur flocons d'avoine, le "l" mou comme une nouille, et le miroir à main au dos d'ivoire du "o" s'occupent des blancs. Je suis perplexe devant mon "on" français que je vois comme la surface tendue et débordante d'alcool dans un petit verre. En passant au groupe bleu, il y a le "x" aciéreux, le "z" couleur nuage d'orage, et le "k" bleuet. Comme il existe une interaction subtile entre le son et la forme, je vois le "q" comme plus brun que le "k", tandis que le "s" n'est pas le bleu clair du "c", mais un curieux mélange d'azur et de nacre. Les teintes adjacentes ne fusionnent pas, et les diphtongues n'ont pas de couleurs spéciales propres, à moins d'être représentées par un seul caractère dans une autre langue (ainsi, la lettre russe gris duveteux à trois tiges qui correspond au "sh", une lettre aussi vieille que les roseaux du Nil, influence sa représentation anglaise)... Dans le groupe vert, il y a le "f" couleur feuille d'aulne, la pomme verte du "p", et le "t" pistache. Un vert terne, combiné en quelque sorte avec du violet, est le mieux que je puisse faire pour le "w". Les jaunes comprennent divers "e" et "i", le "d" crémeux, le "y" doré brillant, et le "u", dont je ne peux exprimer la valeur alphabétique que par "cuivré avec un éclat olive". Dans le groupe brun, il y a le ton riche et caoutchouteux du "g" doux, le "j" plus pâle, et le lacet de chaussure terne du "h". Enfin, parmi les rouges, le "b" a le ton appelé terre de Sienne brûlée par les peintres, le "m" est un pli de flanelle rose, et aujourd'hui j'ai enfin parfaitement associé le "v" au "Rose Quartz" dans le Dictionary of Color de Maerz et Paul. Le mot pour arc-en-ciel, un arc-en-ciel primaire, mais décidément boueux, est dans ma langue privée le presque imprononçable : kzspygv.

[55]

Annexe B

Tableaux Complémentaires

TABLE B.1 : Performances (*losses* finales moyennes sur le jeu de **validation**) par configuration de *losses* et condition d'entraînement (Complet vs Vide Sémantique). Les valeurs sont moyennées sur les instances entraînées.

Configuration	Condition	L_{total}	$L_{translation}$	$L_{contrastive}$	$L_{full-cycle}$	$L_{half-cycle}$
Référence	Complet	0.017	0.005	0.545	0.005	0.003
	Vide Sémantique	0.055	0.094	0.791	0.039	0.007
Emphase Traduction	Complet	0.026	0.003	0.644	0.004	0.006
	Vide Sémantique	0.268	0.089	0.982	0.064	0.012
Emphase Contrastive	Complet	0.128	0.007	0.490	0.011	0.005
	Vide Sémantique	0.192	0.097	0.557	0.081	0.050
Emphase Cycle-Complet	Complet	0.057	0.087	0.805	0.005	0.008
	Vide Sémantique	0.110	0.157	1.286	0.014	0.011
Emphase Attributs Continus	Complet	0.017	0.006	0.555	0.005	0.003
	Vide Sémantique	0.055	0.095	0.792	0.038	0.006

TABLE B.2 : Pourcentage d'instances (sur 3) des Modèles avec Vide Sémantique présentant des distributions de couleurs reconstruites significativement différentes entre **au moins une paire de catégories** d'un attribut, par configuration de *losses* et chemin de transformation.

Configuration	Chemin	Forme (%)	Taille (%)	Pos X (%)	Pos Y (%)	Orientation (%)
Référence	Demi-Cycle	0	0	0	0	0
	Cycle-Complet	0	0	0	0	0
	Traduction	**33**	0	0	0	**100**
Emphase Traduction	Demi-Cycle	0	0	0	0	0
	Cycle-Complet	0	0	0	0	**100**
	Traduction	0	0	0	0	0
Emphase Contrastive	Demi-Cycle	0	0	0	0	0
	Cycle-Complet	0	0	0	0	0
	Traduction	0	0	0	0	0
Emphase Cycle-Complet	Demi-Cycle	0	0	0	0	0
	Cycle-Complet	0	0	0	0	0
	Traduction	**33**	**33**	**33**	0	**100**
Emphase Attributs Continus	Demi-Cycle	0	0	0	0	0
	Cycle-Complet	0	0	0	0	0
	Traduction	**33**	0	0	0	**100**

Annexe C

Analyse des Distributions de Couleurs Reconstruites

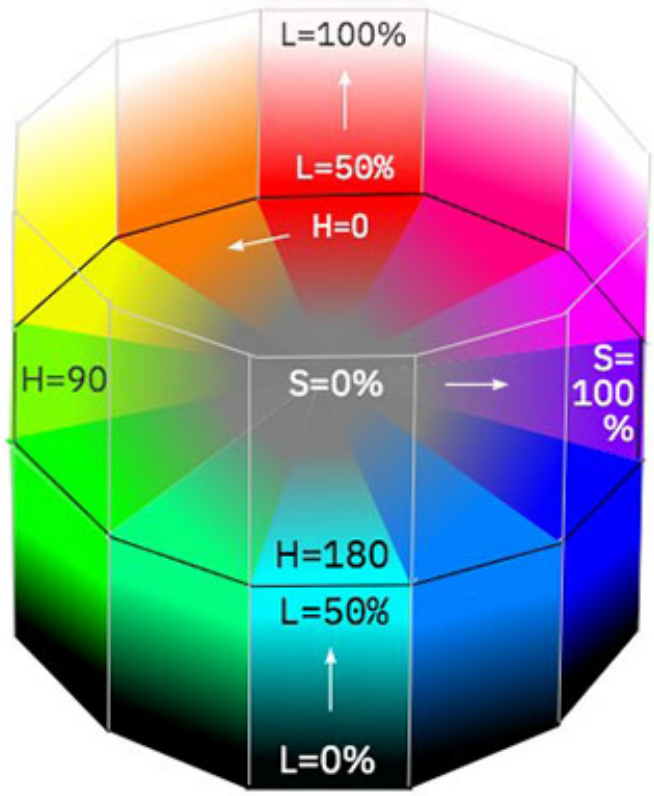


FIGURE C.1 : Représentation du modèle colorimétrique Teinte-Saturation-Luminosité (HSL). La Teinte (H) est l'angle sur le cercle chromatique (ex : H=0 pour le rouge). La Saturation (S) varie de 0% (gris) au centre à 100% (couleur pure) en périphérie. La Luminosité (L) varie de 0% (noir) en bas à 100% (blanc) en haut, avec la couleur la plus pure à L=50%. Ce modèle a été utilisé pour la génération systématique des couleurs du jeu de données de test et l'analyse des teintes reconstruites.

Pour illustrer l'application de notre critère de Régularité, considérons l'exemple de l'attribut Orientation pour une instance de la configuration Référence, sur le chemin de Traduction (Attributs → Image), présenté en Figure C.2. Les heatmaps des p-valeurs (résultats des tests de KS) pour les comparaisons par paires de toutes les catégories d'orientation sont affichées pour le canal Teinte (fig. C.2a) et le canal Rouge (fig. C.2b). Une cellule foncée indique une p-valeur faible (différence significative). Conformément à notre critère (Section 2.3.2), une paire de catégories

d'orientation est considérée comme produisant des couleurs régulièrement distinctes si leurs distributions diffèrent significativement ($p < 0.05$) à la fois sur le canal Teinte ET sur au moins un des canaux RGB. Nous ne présentons ici que la heatmap du canal Rouge pour illustrer ce second aspect, mais les canaux Vert et Bleu sont également pris en compte dans l'analyse complète.

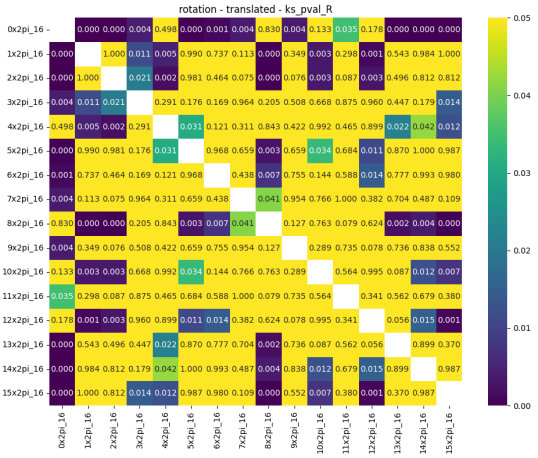
En examinant la première ligne/colonne des heatmaps, correspondant à l'orientation 0, on observe qu'elle présente des différences significatives sur le canal Teinte avec de nombreuses autres orientations (notamment les catégories indexées 5, 6, 7, 9, 10, 11, 13, 14, 15). En consultant ensuite la heatmap du canal Rouge (fig. C.2b), on vérifie lesquelles de ces paires diffèrent également significativement sur ce canal. Par exemple, la paire (0, 10) diffère sur la Teinte mais pas significativement sur le canal Rouge (p-valeur de 0.133 pour R, et des vérifications non montrées ici indiquent qu'elle ne diffère pas non plus sur G ou B). Elle n'est donc pas considérée comme régulièrement distincte. En revanche, les paires (0,5), (0,6), (0,7), (0,9), (0,11), (0,13), (0,14), et (0,15) satisfont le double critère (différence sur Teinte et sur au moins un canal RGB, ici R).

La distinction entre les orientations 0 et $5\pi/8$ (catégorie indexée 5) est détaillée par les histogrammes. La Figure C.2c montre que l'orientation 0 induit un pic de Teinte vers les valeurs extrêmes du cercle chromatique, tandis que l'orientation $5\pi/8$ génère une distribution plus large et décalée. Les distributions des canaux RGB (fig. C.2d pour l'orientation 0, fig. C.2e pour $5\pi/8$) confirment que, par exemple, la composante Rouge est globalement plus élevée et différemment distribuée pour l'orientation 0.

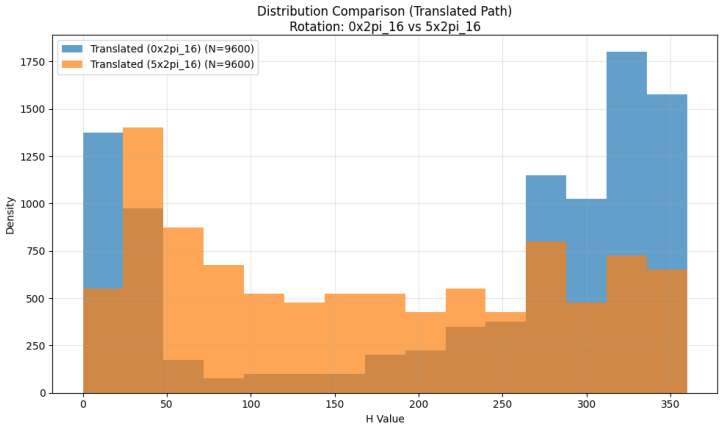
Cet exemple illustre comment, en appliquant nos critères, nous identifions les catégories d'un attribut qui génèrent des couleurs reconstruites régulièrement distinctes au sein d'une même instance de modèle. Pour l'orientation 0 dans cet exemple, elle se distingue ainsi de 8 autres orientations (5, 6, 7, 9, 11, 13, 14, 15).



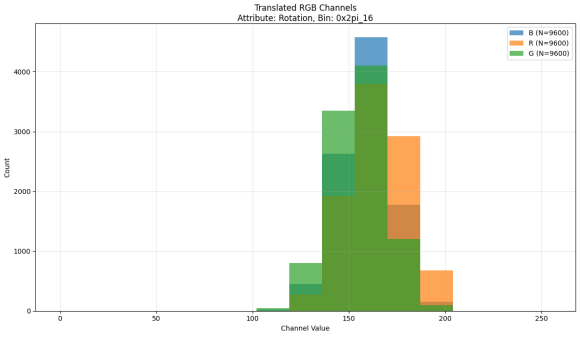
(a) P-valeurs (Teinte) des comparaisons par paires des catégories d'orientation.



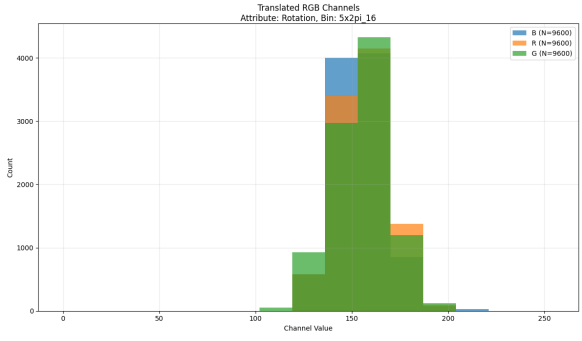
(b) P-valeurs (Canal Rouge) des comparaisons par paires des catégories d'orientation.



(c) Comparaison des distributions de Teinte pour les orientations 0 et $5\pi/8$.



(d) Distributions RGB pour l'orientation 0.



(e) Distributions RGB pour l'orientation $5\pi/8$.

FIGURE C.2 : Illustration du critère de Régularité pour l'attribut Orientation (rotation) sur le chemin de Traduction (Attributs → Image) pour une instance de la configuration Référence. Les heatmaps (a, b) montrent les p-valeurs des tests de KS pour toutes les paires de catégories d'orientation. Les histogrammes (c, d, e) détaillent les distributions de couleurs pour les orientations 0 et $5\pi/8$ ($5 \times 2\pi/16$).

Annexe D

Analyse de la Tendance au Gris en Traduction

D.1 Génération de Gris en Traduction et Interprétation des Résultats

Les images reconstruites par traduction directe Attributs → Image tendent à être achromatiques (grises), comme illustré en Figure 2.1. Ce phénomène, non pleinement anticipé, mérite explication et nous proposons ici une interprétation de son origine et de son impact sur nos analyses.

D.1.1 Proposition d'Explication pour la Tendance au Gris

En l'absence d'information de couleur explicite dans les attributs d'entrée, la fonction de coût de traduction (Attributs → Image) chercherait à optimiser chaque canal RGB indépendamment. Étant donné que les distributions globales d'intensité pour R, G et B dans le jeu d'entraînement sont statistiquement similaires (en raison de S et L constants pour toutes les teintes), leurs espérances mathématiques respectives seraient proches. En conséquence, il est plausible que les valeurs R, G, B prédites par le modèle se resserrent autour d'une valeur commune approximative, correspondant à cette espérance partagée, ce qui se manifeste visuellement par une teinte grise (R≈G≈B). Il ne s'agit pas nécessairement d'une égalité stricte imposée, mais d'une convergence des valeurs vers une moyenne commune, induite par la similarité des distributions sources des canaux.

D.1.2 Interaction avec d'Autres *losses* et Validité des Critères

Bien que la tendance au gris soit prédominante lors de la traduction directe, les autres objectifs d'apprentissage du modèle global peuvent induire des **déviations subtiles mais systématiques** par rapport à ce gris de base, en fonction des attributs.

Cette observation **n'invalide pas nos critères** de détection d'associations couleur-attributs :

- Notre analyse se base sur la détection de **différences statistiquement significatives** dans les distributions de couleur. Même si les couleurs générées sont désaturées ou tendent vers le gris, si le modèle module légèrement mais constamment la couleur (ou le niveau de gris) en fonction d'un attribut, nos tests peuvent le capturer.
- Concernant la Teinte (Hue), l'algorithme de conversion (`colorsys.rgb_to_hls`) assigne par convention la teinte 0 aux gris parfaits (achromatiques, où R=G=B). Si, dans notre encodage, 0 degré correspond également à une teinte chromatique spécifique (par exemple, un rouge pur), cela peut créer une ambiguïté : un pic de teinte à H=0 pourrait indiquer une prédominance de gris *ou* de cette couleur rouge. Cette assignation par défaut de H=0 aux gris pourrait introduire un biais vers cette valeur. Cependant, notre critère de significativité pour une association de couleur requiert une modification statistiquement significative de

la Teinte **et** d'au moins un des canaux R, G, ou B. Ainsi, une simple convergence vers le gris affecterait H (tendant vers 0) et les canaux RGB (tendant vers leur moyenne commune). Une association avec une couleur chromatique spécifique (par exemple, un rouge qui serait aussi à H=0) modifierait H (vers 0) *et* les canaux RGB d'une manière distincte (ex : R augmente, G/B diminuent différemment de la simple convergence vers le gris). Par conséquent, une différence significative dans la distribution de teinte entre catégories d'attributs, interprétée conjointement avec les changements dans les canaux RGB, reste un indicateur valide d'un comportement associatif différentiel du modèle.

En conclusion, la tendance au gris en traduction directe est une conséquence plausible de la structure des données et de l'objectif d'optimisation en l'absence d'information de couleur explicite. Les associations couleur-attributs que nous étudions se manifestent alors comme des modulations statistiquement significatives autour de ce gris. Notre approche d'analyse, qui considère conjointement la Teinte et les canaux RGB pour établir la significativité d'une association, permet de gérer l'ambiguïté potentielle liée à la Teinte 0.

Annexe E

Bonus : Mais où est encodée la saturation ?

La question de l'encodage de la saturation dans nos modèles reste énigmatique. Contrairement à la teinte, dont nous avons pu documenter l'émergence d'associations spécifiques avec les attributs de forme et d'orientation, la saturation semble échapper à notre analyse standard. Pourtant, l'examen qualitatif des reconstructions suggère que cette dimension chromatique est bel et bien présente et variable entre instances. Où cette information est-elle donc stockée ?

À titre exploratoire nous avons vérifié la présence d'informations de couleurs dans les valeurs résiduelles autour de celles codant pour la forme, suivant notre rationnelle d'encodage implicite dans ces valeurs. Pour cela nous avons introduit un vecteur aléatoire de faible amplitude (0.01) dans les vecteurs codant pour la forme. Et testé à nouveau la présence d'associations arbitraires émergentes entres les différents attributs et la couleur. Les résultats sont présentés dans le tableau E.1

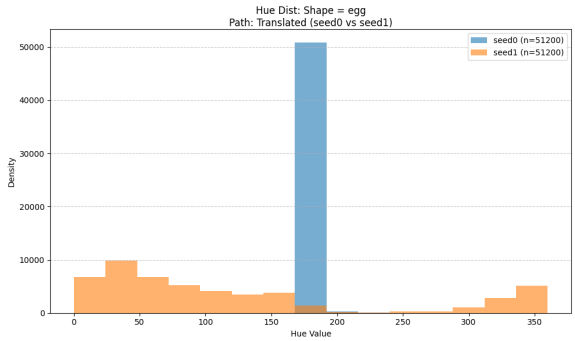
TABLE E.1 : Scores d'arbitraire des associations de couleur par attribut et configuration, sur les chemins de Traduction standard et de Traduction Bruitée (bruit ajouté aux attributs de forme).

Configuration	Chemin	Forme	Taille	Pos X	Pos Y	Orientation
Référence	Traduction	2/2	-	-	-	5/16
	Traduction Bruitée	3/3	0/2	0/4	-	16/16
Emphase Traduction	Traduction	-	-	-	-	-
	Traduction Bruitée	-	-	-	-	-
Emphase Contrastive	Traduction	-	-	-	-	-
	Traduction Bruitée	-	-	-	-	-
Emphase Cycle Complet	Traduction	2/2	0/3	0/2	-	14/16
	Traduction Bruitée	3/3	-	-	-	16/16
Emphase Attributs Continus	Traduction	1/2	-	-	-	1/15
	Traduction Bruitée	3/3	-	0/2	0/2	16/16

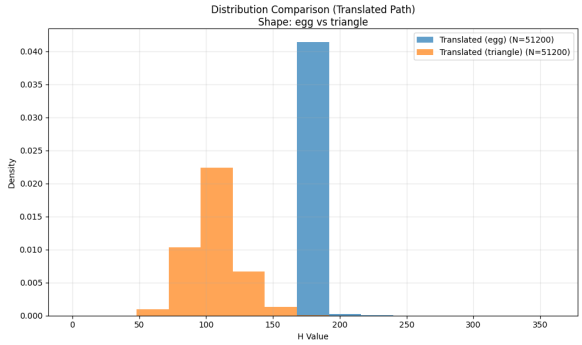
Les valeurs représentent le rapport $\frac{\text{Nb Catégories Spécifiques}}{\text{Nb Catégories Évaluées}}$. Le **numérateur** représente le nombre de catégories dont la distribution de couleurs varie significativement entre instances. Le **dénominateur** correspond au nombre total de catégories de l'attribut qui ont contribué à établir des distinctions inter-catégories régulières (somme sur les trois instances de chaque configuration).

Les résultats obtenus avec l'injection de bruit dans les attributs de forme (Tableau E.1) sont particulièrement instructifs. L'augmentation significative et systématique des scores d'arbitraire pour les attributs Forme et Orientation, notamment dans les configurations où l'émergence sy-

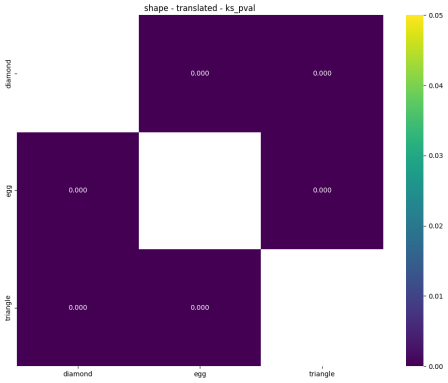
nesthésique était déjà observée, suggère fortement que l'information de couleur (ou du moins ses aspects les plus idiosyncrasiques) était encodée implicitement dans les représentations des attributs. Le faible bruit aléatoire, constant par instance, n'altère pas l'identité de l'attribut mais semble agir comme une sonde qui active ou module les mappings non-linéaires appris par le modèle, révélant ainsi les spécificités d'encodage de chaque instance. L'examen qualitatif (Figure E.1d) suggère, par exemple, que des informations de saturation pourraient être "portées" par ces composantes résiduelles révélées par le bruit.



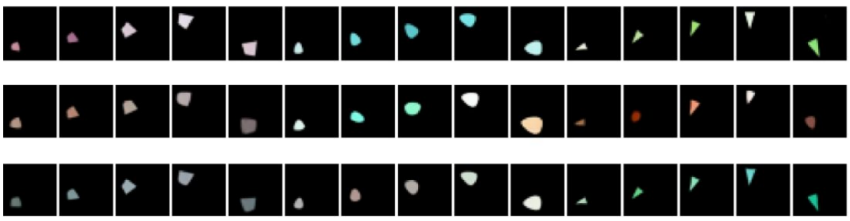
(a) Distributions de teinte pour l'oeuf, instance 0 vs 1 (Traduction Bruitée).



(b) Distributions de teinte pour 'œuf' vs 'triangle' (Traduction Bruitée, Réf.).



(c) P-valeurs (Teinte) des comparaisons par paires des formes (Traduction Bruitée).



(d) Exemples de reconstructions (Traduction Bruitée, Emphase Cycle Complet). Chaque ligne est une instance.

FIGURE E.1 : Illustrations des résultats de l'analyse exploratoire avec bruit ajouté aux attributs de forme. (a) Heatmap des p-valeurs pour la régularité des formes. (b) Comparaison des distributions de teinte entre deux formes (oeuf vs riangle). (c) Exemples visuels des images reconstruites. (d) Comparaison des distributions de teinte pour la même forme (oeuf) entre deux instances.

Les résultats obtenus avec l'injection de bruit dans les attributs de forme (Tableau E.1) sont particulièrement instructifs. L'augmentation significative et systématique des scores d'arbitraire pour les attributs Forme et Orientation, notamment dans les configurations où l'émergence synesthésique était déjà observée (passant par exemple de 2/2 à 3/3 dans les configurations Référence et Emphase Cycle Complet pour la Forme, et de 5/16 à 16/16 pour Référence, de 14/16

à 16/16 pour Emphase Cycle Complet pour l'Orientation), suggère fortement que l'information de couleur (ou du moins ses aspects les plus idiosyncratiques) était encodée implicitement dans les représentations des attributs. Cela démontre que de très petites perturbations introduites dans l'espace des attributs peuvent "révéler" des différences instance-spécifiques dans la couleur reconstruite. Le faible bruit aléatoire, constant par instance, n'altère pas l'identité de l'attribut mais semble agir comme une sonde qui active ou module les mappings non-linéaires appris par le modèle, révélant ainsi les spécificités d'encodage de chaque instance et renforçant l'idée que les associations couleur-attributs apprises sont des mappings complexes et non-linéaires entre l'espace des attributs et l'espace couleur, et non de simples règles discrètes. Un résultat particulièrement notable de cette analyse exploratoire est observé dans la configuration **Emphase Attributs Continus**. Alors que cette configuration réduisait l'arbitraire des associations Forme-Couleur et Orientation-Couleur sur le chemin de Traduction standard (probablement en favorisant des stratégies d'encodage plus uniformes pour la couleur afin de mieux reconstruire les attributs continus), l'ajout de bruit a massivement restauré, voire amplifié, cet arbitraire (Forme : 1/2 à 3/3 ; Orientation : 1/15 à 16/16). Ceci suggère que même lorsque les contraintes d'apprentissage standards lissent les spécificités, les informations nécessaires à l'établissement d'associations instance-spécifiques peuvent persister sous une forme latente, prêtes à être activées par une perturbation appropriée. L'examen qualitatif (Figure E.1d) suggère notamment que des informations de saturation pourraient être encodées dans ces composantes, révélées par le bruit.

Au-delà de l'identification de l'encodage implicite, cette analyse exploratoire soulève également la question de la **robustesse**. L'observation qualitative que les modèles ayant développé des associations synesthésiques artificielles semblent mieux résister à l'introduction de bruit dans les attributs d'entrée que les modèles complets (qui montrent une dégradation marquée de la reconstruction) est une piste très prometteuse. Elle suggère que l'émergence de ces associations intermodales stables pourrait conférer un **avantage fonctionnel** au modèle, en créant potentiellement des voies d'information redondantes ou des mécanismes de compensation qui stabilisent la sortie face à des entrées perturbées. **Ce phénomène rappelle la théorie de la résonance stochastique** (cf. Section 1.1.2), où un niveau optimal de bruit peut améliorer la détection de signaux faibles en activant des mécanismes non-linéaires. Ici, le bruit pourrait révéler ou renforcer l'influence de l'information couleur implicitement encodée.

Ces résultats sont certes exploratoires et basés sur une analyse quantitative limitée à la spécificité inter-instances et une analyse qualitative de la robustesse. Ils ouvrent cependant des perspectives qui méritent une investigation beaucoup plus poussée. Les prochaines étapes devraient inclure :

- Une **quantification rigoureuse de la robustesse** en mesurant la performance de reconstruction ou d'autres métriques pertinentes face à différents niveaux et types de bruit, et en comparant systématiquement les modèles "synesthètes" et complets.
- Une **analyse systématique de l'impact du bruit** appliqué à d'autres attributs (taille, position, orientation) et à différents points de l'architecture (par exemple, directement dans le Global Workspace) pour mieux cerner la localisation et la nature de l'information implicite.
- Une **exploration quantitative plus approfondie des propriétés de couleur** révélées par le bruit (au-delà de la teinte et des canaux RGB, par exemple la saturation, comme suggéré par l'examen qualitatif).
- Le développement d'**hypothèses testables** sur les liens fonctionnels entre l'émergence synesthésique et la robustesse ou d'autres avantages cognitifs potentiels.

En somme, l'effet du bruit dans nos modèles "synesthètes" fournit des indices précieux sur les mécanismes d'encodage implicite de l'information manquante et suggère un lien potentiel entre les associations intermodales émergentes et des propriétés de robustesse. Cette piste exploratoire, bien que préliminaire, souligne l'intérêt de considérer les "gaps informationnels" non pas comme

de simples problèmes à résoudre, mais comme des conditions d'apprentissage pouvant catalyser l'émergence de capacités inattendues et potentiellement avantageuses.

Bien que ces résultats soient encore au stade très préliminaire et nécessitent une quantification plus poussée et une analyse systématique de l'impact du bruit sur l'ensemble des attributs et chemins de traitement, ils fournissent un appui supplémentaire à l'idée que l'asymétrie informationnelle et les contraintes d'apprentissage induisent l'émergence de représentations internes complexes et fonctionnellement pertinentes. Ils suggèrent également que les associations synesthésiques artificielles ne sont pas de simples artefacts, mais pourraient conférer des propriétés désirables aux modèles d'IA, telles qu'une meilleure résilience aux variations subtiles des données d'entrée.